

Universidad de La Habana
Facultad de Matemática y Computación



Análisis comparativo de métodos aproximados en solucionadores CDCL SAT

Autora:

Massiel Paz Otaño

Tutor:

Dr. Luciano García Garrido

Trabajo de Diploma
presentado en opción al título de
Licenciada en Ciencia de la Computación

Fecha

github.com/NinaSayers/Application-of-Computational-Logic-in-Problem-Solving.git

Dedicación

Agradecimientos

Agradecimientos

Opinión del tutor

Opiniones de los tutores

Resumen

Esta tesis realiza un análisis comparativo de las heurísticas de decisión de variables VSIDS (Variable State Independent Decaying Sum) y DLIS (Dynamic Largest Individual Sum) en solvers SAT basados en Conflict-Driven Clause Learning (CDCL). El estudio examina ambas heurísticas con y sin estrategias de *restart*, utilizando como plataforma de evaluación el solver CaDiCaL.

Se implementó DLIS en CaDiCaL mediante modificaciones que permitieron su integración con la estructura existente del solver y sus otras heurísticas. Para la evaluación, se desarrolló un benchmark de 135 problemas SAT mediante un script Python, abarcando diversas categorías: random k-sat, random biased k-sat, pigeonhole, graph coloring, parity XOR y BCM flip flop. Estos problemas presentan variaciones en sus estructuras, incluyendo números de variables (desde decenas hasta miles), cantidad de cláusulas y densidad de restricciones.

Cada combinación heurística (VSIDS/DLIS, con/sin *restart*) se ejecutó sobre todos los problemas mediante flags específicos de CaDiCaL, estableciendo un timeout de 2 minutos por ejecución. Los resultados se almacenaron sistemáticamente en un CSV, registrando: nombre del problema, heurística empleada, resultado (SATISFIABLE/UNSATISFIABLE/TIMEOUT), tiempo de resolución, cantidad de variables, cantidad de cláusulas y densidad.

El análisis estadístico reveló que el rendimiento depende más de la estructura intrínseca del problema que de la heurística específica o el uso de *restart*. No se observaron diferencias significativas entre DLIS con/sin *restart* ni entre VSIDS con/sin *restart*. Sin embargo, VSIDS exhibió mayor varianza en los tiempos de ejecución, mientras DLIS demostró ser más eficiente para problemas específicos como los de coloración de grafos y estructuras XOR-parity. Estos hallazgos sugieren que la selección óptima de heurísticas debería considerar las características estructurales de los problemas SAT a resolver.

Abstract

Resumen en inglés This Bachelor's Thesis in Computer Science conducts a comparative analysis of variable decision heuristics VSIDS (Variable State Independent Decaying Sum) and DLIS (Dynamic Largest Individual Sum) in Conflict-Driven Clause Learning (CDCL) SAT solvers. The study examines both heuristics with and without restart strategies, using the CaDiCaL solver as the evaluation platform.

DLIS was implemented in CaDiCaL through modifications that enabled its integration with the solver's existing structure and other heuristics. For evaluation, a benchmark of 135 SAT problems was developed using a Python script, covering diverse categories: random k-sat, random biased k-sat, pigeonhole principle, graph coloring, parity XOR, and BCM flip flop. These problems feature structural variations including variable counts (from tens to thousands), clause quantities, and constraint densities.

Each heuristic combination (VSIDS/DLIS, with/without restart) was executed on all problems using specific CaDiCaL flags, with a 2-minute timeout per execution. Results were systematically stored in a CSV file, recording: problem name, heuristic used, outcome (SATISFIABLE/UNSATISFIABLE/TIMEOUT), resolution time, variable count, clause count, and density.

Statistical analysis revealed that performance depends more on the intrinsic structure of the problem than on the specific heuristic or restart usage. No significant differences were observed between DLIS with/without restart or VSIDS with/without restart. However, VSIDS exhibited greater variance in execution times, while DLIS proved more efficient for specific problems such as graph coloring and XOR-parity structures. These findings suggest that optimal heuristic selection should consider the structural characteristics of target SAT problems.

Índice general

Introducción	1
1. Marco Teórico	5
1.1. Fundamentos de los Problemas de Satisfacción de Restricciones y SAT	5
1.1.1. SAT como Caso Especial de CSP y su NP-Complejidad	5
1.1.2. Relación Práctica entre CSPs y SAT	6
1.2. Evolución de los SAT <i>solvers</i> : Principio de Resolución, DP, DPLL y CDCL	6
1.2.1. Principio de Resolución	7
1.2.2. Algoritmo Davis–Putnam (DP)	8
1.2.3. Algoritmo Davis–Putnam–Logemann–Loveland (DPLL)	9
1.2.4. <i>Conflict-Driven-Clause-Learning</i> (CDCL)	12
1.3. Heurísticas	14
1.3.1. <i>Dynamic Largest Individual Sum</i> (DLIS)	14
1.3.2. <i>Variable State Independent Decaying Sum</i> (VSIDS)	15
1.3.3. Reinicio (<i>restart</i>)	16
1.3.4. <i>Two Watched Literals</i> (TWL)	19
1.4. CaDiCaL	20
1.4.1. Ramificación (selección de variables)	20
1.4.2. Políticas de reinicio	20
1.4.3. <i>Assumptions</i>	21
1.4.4. <i>Phasing</i>	22
1.4.5. Modularidad y Extensibilidad del Código de CaDiCaL	23
1.4.6. Ventajas de CaDiCaL para Experimentación	23
1.5. Parámetros de Evaluación para <i>solvers</i> CDCL: Taxonomía de exit- Benchmarks	24
1.5.1. Categorías	24
1.5.2. Clasificación por Satisfacibilidad y Propiedades Estructurales .	24
1.5.3. Densidad y Transición de Fase	25
1.5.4. Relevancia para la Evaluación de Heurísticas	25

1.6.	Problemas	25
1.6.1.	Random k -SAT	25
1.6.2.	Problema del palomar	26
1.6.3.	Problema de coloreo de grafos	26
1.6.4.	XOR	27
1.6.5.	<i>Bounded Model Checking</i> (BCM)	27
1.7.	Ineficiencias Fundamentales de SAT	27
2.	Detalles de Implementación y Experimentos	30
2.0.1.	CaDiCaL	30
2.0.2.	Empleo de <i>flags</i> en la línea de comandos	35
2.0.3.	Problemas	35
2.0.4.	Generador de problemas	37
2.0.5.	Estadísticas	37
2.1.	Resultados	38
2.1.1.	Análisis de los problemas con TIMEOUT	38
2.1.2.	Análisis de problemas resueltos (SATISFIABLE/UNSATISFIABLE)	40
2.1.3.	Problemas RESUELTOS vs TIMEOUT	41
2.1.4.	Rendimiento de las heurísticas en problemas resueltos	43
	Conclusiones	47
	Recomendaciones	48

Índice de figuras

1.1. Posible espacio de búsqueda de una FNC (citar libro de Luciano) . . .	10
--	----

Ejemplos de código

Introducción

El desarrollo de la lógica computacional como disciplina se enmarca en la revolución tecnológica del siglo XX, impulsada por la necesidad de resolver problemas complejos en ámbitos como la inteligencia artificial, la verificación de hardware y software, y la optimización industrial. La creciente demanda de sistemas automatizados capaces de procesar restricciones y tomar decisiones eficientes llevó a la comunidad científica a explorar métodos formales para modelar y resolver problemas combinatorios. En este escenario, la teoría de la complejidad computacional emergió como un pilar fundamental, especialmente tras la identificación de la clase NP-Completo por Cook en 1971, que transformó la comprensión de los límites de la computación.

Los problemas con restricciones —aquellos que requieren satisfacer un conjunto de condiciones lógicas— han sido centrales en áreas como la planificación, la criptografía y el diseño de circuitos. El problema de satisfacibilidad booleana (SAT), demostrado por Cook como el primer problema NP-Completo, se convirtió en la piedra angular para estudiar la viabilidad de soluciones eficientes. Aunque los primeros algoritmos para SAT, como el método de Davis-Putnam (DP) y su evolución, Davis-Putnam-Logemann-Loveland (DPLL), sentaron las bases de los *solvers*, su eficiencia se veía limitada por la explosión combinatoria en instancias complejas. La presencia de cláusulas unitarias, la selección subóptima de variables y el retroceso (backtrack) cronológico exponían claras debilidades, especialmente en problemas con miles de variables.

A pesar de los avances, los SAT *solvers* clásicos enfrentaban un desafío crítico: escalar sin sacrificar completitud. Esto motivó la búsqueda de mejoras heurísticas y estratégicas, como el aprendizaje de cláusulas y el *backtrack* no cronológico, que culminaron en el surgimiento del paradigma Conflict-Driven Clause Learning (CDCL). CDCL no solo optimizó la exploración del espacio de soluciones, sino que introdujo mecanismos para evitar repeticiones de conflictos, marcando un hito en la resolución práctica de problemas NP-Completo.

El núcleo de la eficiencia de los SAT *solvers* modernos reside, sin lugar a dudas, en su capacidad para reducir el espacio de búsqueda de forma inteligente. Sin embargo, incluso con técnicas como CDCL, un desafío persiste: la selección óptima de variables. Esta elección determina la dirección en la que el algoritmo explora el árbol

de decisiones, y una estrategia subóptima puede llevar a ciclos de conflicto-reparación redundantes, incrementando exponencialmente el tiempo de ejecución. En problemas NP-Complejos, donde el número de posibles asignaciones crece como 2^n (con n variables), una heurística de selección inadecuada convierte instancias resolubles en minutos en problemas intratables.

En CDCL, tras cada conflicto, el solucionador aprende una cláusula nueva para evitar repeticiones. No obstante, la eficacia de este aprendizaje depende de qué variables se eligieron para bifurcar el espacio de soluciones. Si se seleccionan variables irrelevantes o poco conectadas a los conflictos, las cláusulas aprendidas serán débiles o redundantes, limitando su utilidad. Así, la selección de variables no es solo una cuestión de orden, sino de calidad de la exploración.

Dos de las heurísticas de selección de variables son VSIDS (Variable State Independent Decaying Sum) y DLIS (Dynamic Largest Individual Sum). Ambas, son aproximaciones *greedy*, dado que optimizan localmente (paso a paso) sin garantizar una solución global óptima. Su eficacia depende de cómo la estructura del problema se alinee con sus criterios. Por una parte, VSIDS asigna un puntaje a cada variable, incrementándolo cada vez que aparece en una cláusula involucrada en un conflicto. Periódicamente, estos puntajes se reducen (*decaimiento* exponencial), priorizando variables activas recientemente. Por otra parte, DLIS calcula, para cada literal (variable o su negación), el número de cláusulas no satisfechas donde aparece. Selecciona el literal con mayor frecuencia y asigna su variable correspondiente.

En los CDCL SAT *solvers* se ha observado que el tiempo de ejecución puede seguir una distribución de “cola pesada” (*heavy-tailed distribution*), lo que significa que el solucionador puede quedarse atascado en un camino de búsqueda improductivo por un tiempo prolongado. En aras de resolver este problema, surge la estrategia *restart*, la cual borra parte del estado del *solver* a intervalos determinados durante su ejecución. Su principal objetivo es reorientar la búsqueda y aprovechar el conocimiento acumulado mientras se evita profundizar en regiones improductivas del árbol de búsqueda. Al reiniciar, el resolutor puede escapar de una dirección de búsqueda desventajosa y tener una “segunda oportunidad” para encontrar una solución más rápidamente.

Hoy, aunque los SAT solucionadores basados en CDCL dominan aplicaciones críticas, desde la verificación formal de chips hasta la síntesis de programas, su rendimiento varía significativamente según el tipo de problema (p. ej., aleatorios vs. estructurados) y las heurísticas empleadas. Mientras VSIDS prioriza variables recientemente involucradas en conflictos —útil en problemas con alta estructura local—, DLIS enfatiza la frecuencia de aparición de literales, mostrando ventajas en dominios con distribución uniforme de restricciones. Esta dualidad plantea preguntas clave: ¿bajo qué métricas (tiempo de ejecución, memoria, escalabilidad) una estrategia supera a la otra? ¿Cómo influye la naturaleza del problema en su eficiencia?

Esta tesis aporta una comparación sistemática entre VSIDS y DLIS, alternando

entre el uso de *restart* dentro del entorno CDCL que ofrece el solucionador CaDiCaL, evaluando su desempeño en problemas heterogéneos (industriales, aleatorios y académicos). A diferencia de estudios previos, se integran métricas adaptativas que consideran no solo el tiempo de resolución, sino también el impacto de las características de los problemas. Además, se propone un marco teórico amplio para comprender la evolución algorítmica de los CDCL SAT *solvers*, entender algunas de las heurísticas que se emplean en los solucionadores modernos, específicamente en CaDiCaL, y clasificar problemas según su afinidad heurística, contribuyendo a la selección informada de algoritmos en aplicaciones reales.

Teóricamente, este trabajo profundiza en la relación entre estructura de problemas y heurísticas, enriqueciendo la comprensión de CDCL. Prácticamente, ofrece directrices para ingenieros y desarrolladores de *solvers*, optimizando recursos en áreas como la verificación de *software* o la logística, donde minutos de mejora equivalen a ahorros millonarios.

Como problema científico se plantea la ineficiencia de los SAT solucionadores ante problemas con distintas estructuras, asociada a la selección subóptima de variables, influenciada o no por técnicas de reinicio. El objeto de estudio se centrará en algoritmos CDCL con estrategias VSIDS, DLIS y *restart*. Esta tesis tiene como objetivos:

- Analizar el impacto de VSIDS y DLIS, con y sin reinicio, en el rendimiento de CDCL.
- Establecer correlaciones entre tipos de problemas y heurísticas.
- Establecer correlaciones entre tipos de problemas y resultados de las heurísticas.

El campo de acción de esta tesis versa sobre la Lógica computacional aplicada a la resolución de problemas con restricciones. Como hipótesis se plantea que: El rendimiento de VSIDS y DLIS con y sin *restart* varía significativamente según la densidad de restricciones, el tamaño promedio de cláusula y la cantidad de variables. Esta investigación busca no solo esclarecer el debate entre VSIDS y DLIS, sino también sentar bases para el diseño de heurísticas adaptativas, impulsando la próxima generación de resolutores.

El documento se organiza en cinco capítulos:

- **Capítulo 1** Revisión teórica de los principales algoritmos usados en los SAT solvers, algunas heurísticas empleadas en los *solvers* modernos haciendo énfasis en CaDiCaL, y de las categorías de problemas usadas en el análisis de eficiencia de los solucionadores SAT.
- **Capítulo 2** Detalles de implementación de las heurísticas en CaDiCaL, del generador de problemas y de los análisis estadísticos empleados.

- **Capítulo 3** Resultados de los experimentos.
- **Capítulo 4** Conclusiones y recomendaciones.

Capítulo 1

Marco Teórico

1.1. Fundamentos de los Problemas de Satisfacción de Restricciones y SAT

Los Problemas de Satisfacción de Restricciones (CSP, por sus siglas en inglés) constituyen un paradigma esencial para la modelación de problemas combinatorios en inteligencia artificial, investigación operativa y ciencias de la computación. Formalmente, un CSP se define como una tripleta (V, D, C) , donde V representa un conjunto de variables, D sus dominios discretos finitos, y C un conjunto de restricciones que determinan las combinaciones válidas de valores **garcia_conferencia1**. Por ejemplo, en un problema de asignación de horarios, V corresponde a los cursos, D a los horarios disponibles, y C a las reglas que impiden superposiciones. La solución del problema consiste en una asignación de valores a las variables que satisface todas las restricciones, y en algunos casos, adicionalmente, optimiza ciertos criterios como la utilización de recursos **40**.

1.1.1. SAT como Caso Especial de CSP y su NP-Complejidad

El Problema de Satisfacibilidad Booleana (SAT, por sus siglas en inglés) se considera un caso particular de CSP, en el cual los dominios de las variables son binarios $(0, 1)$ y las restricciones se expresan mediante fórmulas en Forma Normal Conjuntiva (FNC) **43**. Una fórmula en FNC se compone de una conjunción de cláusulas, donde cada cláusula es una disyunción de literales, es decir, variables o sus negaciones **6**. Resolver un problema SAT implica determinar si existe una asignación de valores que satisfaga simultáneamente todas las cláusulas, lo cual equivale a resolver un CSP binario con restricciones específicas.

La importancia teórica de SAT se fundamenta en su clasificación como problema NP-completo, establecida por Cook y Levin en 1971 **2,24**. Esta clasificación conlleva

dos implicaciones fundamentales: en primer lugar, cualquier problema perteneciente a la clase NP puede reducirse a una instancia de SAT en tiempo polinomial **26**; en segundo lugar, la existencia de un algoritmo de tiempo polinomial que resuelva SAT implicaría que $P = NP$, lo cual provocaría un colapso en la jerarquía de complejidad computacional **2**. Si bien en la práctica los solucionadores actuales logran resolver instancias que contienen millones de variables **3**, en el peor de los casos SAT presenta una complejidad exponencial intrínseca **27**.

1.1.2. Relación Práctica entre CSPs y SAT

Si bien los CSPs permiten modelar problemas con dominios arbitrarios y restricciones globales —lo cual representa una ventaja frente a la rigidez booleana de SAT—, su resolución directa mediante técnicas como *backtracking* o la aplicación de consistencia de arco presenta limitaciones similares en cuanto a escalabilidad **46**. Como respuesta a estas limitaciones, se recurre frecuentemente a la traducción de CSPs a SAT, con el objetivo de aprovechar las décadas de avances en la optimización de solucionadores CDCL?? **44**. Estudios empíricos muestran que ciertas codificaciones eficientes pueden reducir hasta en un 60% el tiempo de resolución en comparación con enfoques nativos basados en CSPs **45**.

Sin embargo, dicha traducción conlleva compromisos. Mientras SAT se adapta mejor a restricciones locales y cláusulas pequeñas, los CSPs ofrecen mecanismos más adecuados para el tratamiento de restricciones globales. En contextos como la asignación de turnos hospitalarios, los modelos CSP con restricciones de recursos logran resolver instancias en minutos, mientras que sus equivalentes codificados en SAT pueden requerir varias horas debido a la proliferación de cláusulas **46**. Esta dicotomía resalta la necesidad de seleccionar el paradigma de resolución en función de la estructura del problema.

1.2. Evolución de los SAT *solvers*: Principio de Resolución, DP, DPLL y CDCL

La evolución de los solucionadores SAT constituye un hito en la ciencia de la computación, pues convierte un problema teóricamente intratable en una herramienta práctica de amplio uso industrial. Este desarrollo se apoya en tres pilares algorítmicos: el Principio de Resolución, los métodos Davis-Putnam y Davis-Putnam-Logemann-Loveland, y la revolución moderna impulsada por los solucionadores de aprendizaje de cláusulas dirigido por conflictos (*Conflict Driven-Clause Learning*). A continuación, se presenta un análisis detallado de cada uno.

1.2.1. Principio de Resolución

El Principio de Resolución (PR), propuesto originalmente en el contexto de la lógica proposicional, constituye la base teórica de numerosos algoritmos SAT. Este, permite derivar nuevas cláusulas a partir de pares de cláusulas que contienen literales complementarios, reduciendo progresivamente la fórmula hasta detectar una contradicción o verificar su satisfacibilidad.

Dada una fórmula en Forma Normal Conjuntiva, cada una de sus cláusulas se representa como un conjunto de literales, y a su vez la fórmula se prerepresenta como un conjunto de conjuntos. Por esta razón no hay elementos repetidos dentro de una cláusula ni en la fórmula completa. Tomando como entrada esta representación, PR identifica pares de cláusulas que contienen literales complementarios (q y $\neg q$) y genera una nueva cláusula al realizar la operación de unión entre ellas y eliminando de cada una el literal y su opuesto. (citar libro de la Lógica Proposicional de Luciano)

Concretamente, si \mathbf{B} y \mathbf{C} son cláusulas de la FNC \mathbf{A} tales que $l \in \mathbf{B}$ y $\neg l \in \mathbf{C}$, entonces la cláusula resultante se define como:

$$\mathbf{D} = (\mathbf{B} \setminus \{l\}) \cup (\mathbf{C} \setminus \{\neg l\})$$

En este proceso, \mathbf{B} y \mathbf{C} actúan como cláusulas padres o premisas, mientras que \mathbf{D} corresponde al solvente o conclusión.

Por ejemplo, la resolución de las cláusulas

$$\{\neg p, \neg q, \neg r\} \quad y \quad \{\neg p, q, \neg r\}$$

produce

$$\{\neg p, \neg r\}$$

Asimismo, la combinación de

$$\{\neg q\} \quad y \quad \{q\}$$

conduce a la cláusula vacía, lo que evidencia la insatisfacibilidad de la fórmula. (citar libro de la Lógica Proposicional de Luciano)

Resolución Unitaria (RU)

Una instancia particular de PR es la Resolución Unitaria (RU), en la cual una de las premisas es una cláusula unitaria¹. Este caso especial adquiere relevancia por su simplicidad y eficiencia, ya que permite deducciones inmediatas a partir de asignaciones forzadas.

¹Una cláusula que contiene un único literal, y por tanto, fuerza su valor a ser verdadero bajo una interpretación determinada.

El proceso consiste en identificar una cláusula unitaria y aplicar PR sobre otra cláusula que contenga el literal complementario, eliminándolo y generando una nueva cláusula más restringida. Por ejemplo:

$$\frac{\{\neg q, p, \neg r\}, \{r\}}{\{\neg q, p\}}$$

En este caso, la cláusula unitaria $\{r\}$ permite simplificar la cláusula $\{\neg q, p, \neg r\}$, eliminando el literal $\neg r$ y generando una nueva cláusula $\{\neg q, p\}$. Esta operación puede aplicarse iterativamente, facilitando la propagación de valores lógicos en la fórmula original, y constituye un componente fundamental en algoritmos como DPLL1.2.3 y CDCL1.2.4, donde se utiliza para propagar restricciones a lo largo del proceso de asignación.

El Principio de Resolución, aunque es completo para fórmulas en FNC, su aplicación directa resulta impráctica debido al crecimiento exponencial en el número de cláusulas generadas **12**. Sin embargo, su relevancia conceptual fundamenta y guía el diseño de métodos más eficientes.

1.2.2. Algoritmo Davis–Putnam (DP)

Uno de los primeros algoritmos propuestos para la resolución del problema SAT fue el de Davis-Putnam (DP), cuyo funcionamiento se basa en gran medida en el Principio de Resolución. Este algoritmo implementa tres procedimientos fundamentales: la Propagación Unitaria (PU), la Eliminación de Literales Puros (ELP) y la Resolución Basada en División (RD).

La Propagación Unitaria identifica cláusulas unitarias dentro de la FNC y procede a asignar forzosamente el valor correspondiente al literal involucrado. Seguidamente, elimina de la fórmula todas las cláusulas satisfechas por dicha asignación, y suprime el literal complementario en aquellas donde aparezca. Por su parte, la Eliminación de Literales Puros detecta literales cuya polaridad es única en toda la fórmula² y elimina las cláusulas en las que aparezcan. Este procedimiento persigue la idea de que las cláusulas con literales puros pueden satisfacerse directamente sin afectar la satisfacibilidad de la fórmula. Tanto PU como ELP se consideran técnicas de preprocesamiento destinadas a simplificar la FNC antes de aplicar los pasos recursivos del algoritmo.

Una vez realizadas estas simplificaciones, DP procede con la Resolución Basada en División, que consiste en seleccionar una variable, asignarle un valor (0 o 1) y continuar la resolución de forma recursiva a partir de la nueva fórmula. Esta estrategia permite explorar sistemáticamente el espacio de soluciones posibles hasta determinar si la fórmula es satisfacible o no. (citar libro de Luciano Lógica Proposicional)

²se dice que q es un literal puro en la FNC A si q ocurre en A y $\neg q$ no

Véase el siguiente ejemplo para una mejor comprensión.

Sean las siguientes fórmulas de la Lógica Proposicional:

$$r, \quad [q \wedge r] \implies p, \quad [q \vee r] \implies \neg p, \quad [\neg q \wedge r] \implies \neg p, \quad \neg s \implies p$$

A partir de la conjunción de estas proposiciones, se obtiene la siguiente FNC:

$$\{\{r\}, \{p, \neg q, \neg r\}, \{\neg p, \neg q\}, \{\neg p, \neg r\}, \{\neg p, q, \neg r\}, \{p, s\}\}$$

Aplicando **Propagación Unitaria (PU)** sobre la cláusula unitaria $\{r\}$, se eliminan todas las cláusulas que contienen r y se suprime $\neg r$ de las restantes:

$$\{\{p, \neg q\}, \{\neg p, \neg q\}, \{\neg p\}, \{\neg p, q\}, \{p, s\}\}$$

Posteriormente, al aplicar **PU** sobre la cláusula unitaria $\{\neg p\}$, se elimina toda cláusula que contenga $\neg p$ y se remueve p de las demás:

$$\{\{\neg q\}, \{s\}\}$$

Aplicando nuevamente **PU** sobre $\{\neg q\}$:

$$\{\{s\}\}$$

Y finalmente, aplicando **PU** sobre $\{s\}$:

$$\{\}$$

Dado que la fórmula ha sido completamente reducida sin generar contradicciones, se concluye que la instancia es satisfacible. (citar libro de Luciano de L'ogica Proposicional)

Cabe señalar que el algoritmo Davis-Putnam requiere memoria exponencial en el peor de los casos, ya que explora todas las asignaciones posibles para las variables. Esto se traduce en un árbol de decisión cuyo tamaño crece exponencialmente con el número de variables involucradas.

1.2.3. Algoritmo Davis–Putnam–Logemann–Loveland (DPLL)

El algoritmo Davis-Putnam-Logemann-Loveland (DPLL) constituye una mejora significativa del método DP, al preservar sus fundamentos teóricos y superar una de sus principales limitaciones: el consumo exponencial de memoria. Para ello, DPLL incorpora un mecanismo de retroceso (exitbacktracking) cronológico que le permite deshacer asignaciones al regresar al nivel anterior de decisión una vez detectada




Figura 1.1: Posible espacio de búsqueda de una FNC (citar libro de Luciano)

una “cláusula de conflicto”³. Este enfoque permite explorar el árbol de búsqueda de forma más eficiente, reduciendo la necesidad de almacenar todas las ramas posibles.

DPLL adopta una estrategia de generación “lazy” del árbol de asignaciones: antes de realizar una nueva ramificación, verifica mediante propagación unitaria si existen conflictos que invaliden dicha extensión. Esta verificación garantiza que las asignaciones parciales se mantengan consistentes, y que las soluciones (cuando existen) se ubiquen en las hojas del árbol de decisión. En caso de que el conflicto se produzca en el nivel de decisión cero, y ambas asignaciones posibles para la variable de este nivel hayan sido consideradas, se concluye que la fórmula es insatisfacible. En conjunto, el procedimiento de DPLL puede resumirse como una combinación de ramificación, propagación unitaria y retroceso sistemático.

Adicionalmente, DPLL incluye una etapa de preprocesamiento sobre la FNC, en la cual se aplican simplificaciones basadas en leyes de la Lógica Proposicional. Entre estas se encuentra la eliminación de cláusulas redundantes mediante el principio de subsunción⁴. Estas técnicas contribuyen a reducir el tamaño de la instancia antes de la búsqueda propiamente dicha, mejorando la eficiencia del algoritmo sin comprometer su completitud. (citar libro de Luciano)

Obsérvese el siguiente ejemplo:

Sea la FNC:

³Se denomina cláusula de conflicto a aquella en la que todos sus literales fueron evaluados como falsos bajo una asignación parcial.

⁴Sean C y C' dos cláusulas de una FNC; si $C' \subseteq C$, entonces C se considera subsumida por C' y puede eliminarse sin alterar la satisfacibilidad de la fórmula. En otras palabras, C es una cláusula redundante.

$$\{\{\neg p, \neg q\}, \{\neg p, \neg q\}, \{\neg p, q, \neg r\}, \{\neg p, r, s\}, \{p, s\}\}$$

Simplificando mediante la ley de absorción:

$$\{\{\neg p, \neg q\}, \{\neg p, q, \neg r\}, \{\neg p, r, s\}, \{p, s\}\}$$

Eliminando el literal puro s :

$$\{\{\neg p, \neg q\}, \{\neg p, q, \neg r\}\}$$

Ramificando: $p = 1$

$$\{\{\neg q\}, \{q, \neg r\}\}$$

Aplicando **PU** en $\{\neg q\}$:

$$\{\{\neg r\}\}$$

Aplicando **PU** en $\{\neg r\}$:

$$\emptyset$$

Luego, la FNC es satisfacible. (citar libro de Luciano)

No obstante la reducción del espacio de memoria de DPLL respecto a DP, aún persisten problemas fundamentales: la selección de variables, el *backtrack* cronológico y la elección de cláusulas unitarias.

En primer lugar, la selección de la variable a la que se asignará un valor influye directamente en la “forma” del espacio de búsqueda. Una decisión inapropiada puede derivar en caminos significativamente más largos hacia una solución. Por tanto, resulta crucial emplear heurísticas que optimicen esta elección. (poner ejemplo)

En segundo lugar, el *backtrack* cronológico ante un conflicto obliga a explorar, posiblemente de forma innecesaria, las asignaciones alternativas en niveles anteriores. Esta ineficiencia se acentúa cuando la causa real del conflicto se encuentra a k niveles de distancia del punto donde se detectó. Además, DPLL no capitaliza las cláusulas que originaron los conflictos; es decir, no “aprende” de ellos. En consecuencia, es susceptible de incurrir reiteradamente en los mismos patrones erróneos de asignación.

Finalmente, el problema de la selección de cláusulas unitarias también repercute en la eficiencia del algoritmo, estando íntimamente relacionado con la estrategia de selección de variables.

1.2.4. *Conflict-Driven-Clause-Learning* (CDCL)

CDCL es una mejora que se le añadió al algoritmo DPLL con el objetivo de erradicar el problema del retroceso (*backtrack*) cronológico, una vez encontrada una cláusula de conflicto.

El retroceso cronológico consiste en recorrer el árbol de decisión (estructura propia del algoritmo DPLL que se forma al asignarle valores a las variables) retrocediendo de a 1 por cada nivel, probando todos los valores aún sin explorar de cada variable hasta encontrar la asignación causante del conflicto. Esta búsqueda es ineficiente pues además de analizar casos innecesarios, se vuelve susceptible a cometer el mismo error en el futuro dado que, potencialmente, realizará la misma combinación de asignaciones, lo cual genera búsquedas redundantes.

Para solucionar este problema, CDCL crea un grafo dirigido y acíclico que permite guardar el historial de asignaciones de cada variable. En dicho grafo, los nodos son las variables y los arcos constituyen la causa de la asignación de dicha variable: la cláusula a la que pertenece, si fue asignada por propagación unitaria, y `null` para variables asignadas por decisión. Igualmente, se almacenan los siguientes datos: el valor asignado a cada variable (0 o 1) y el nivel de decisión en el que se asignó (los diferentes niveles de decisión están marcados por la asignación de valores por decisión). Cabe destacar que la dirección de los arcos en el grafo va desde las variables de decisión hacia aquellas que, en el mismo nivel, tuvieron que forzar su valor por propagación unitaria. En el caso de una nueva variable de decisión, se crea un nuevo arco con valor `null` desde la variable asignada por decisión en el nivel anterior hasta la nueva variable. (insertar img de ejemplo de grafo)

Cuando una cláusula resulta ser de conflicto (sus literales evaluaron 0), CDCL crea un nuevo nodo en el grafo que representa dicho conflicto para comenzar con su análisis. Este, busca en el grafo la asignación causante del conflicto, para retroceder justo hacia ese punto y realizar un *backjump* en lugar de un retroceso cronológico, como en DPLL. En caso de que el nivel del *backjump* sea el nivel 0, CDCL considera la FNC como insatisfacible. Asimismo, con este análisis CDCL busca conformar una “cláusula aprendida” que represente la combinación de asignación de valores que condujo a dicho conflicto, y la añade al conjunto de cláusulas. De esta forma, evita cometer el mismo error en iteraciones futuras. El punto escogido para realizar el *backjump* es conocido como primer punto de implicación único (*First-UIP* por sus siglas en inglés). Este punto será aquel literal que, en la cláusula aprendida, posea el más alto nivel de decisión diferente del actual. (añadir figura de First-UIP en el grafo)

Es necesario enfatizar en el hecho de que la cláusula aprendida debe contener **únicamente** un literal cuyo valor haya sido asignado en el nivel de decisión actual. En caso de haber más de uno, CDCL recorre el grafo en busca de la cláusula que causó la asignación de una de estas variables y aplica el PR entre esta y la cláusula

aprendida hasta el momento. La cláusula resultante pasará a ser la nueva cláusula aprendida. El proceso se repetirá hasta que la cláusula aprendida contenga solo un literal cuyo valor fue asignado en el nivel de decisión actual.

En el código Abrir código fuente se muestra un ejemplo de implementación en *Python* de un CDCL SAT *solver*

La implementación anterior consiste en una clase *SATSolver* que realiza los pasos del algoritmo CDCL, dada una FNC escrita como un *array* de *arrays*, donde estos últimos representan las cláusulas. Cada variable está representada por un número entero positivo, y sus literales son ese número o su opuesto (negado).

El método `__init__(self, formula)` inicializa las estructuras internas:

- *assignments*: Mapea cada variable con su valor asignado (*True* o *False*).
- *levels*: Mapea cada variable con el nivel de decisión en que fue asignada.
- *reasons*: Mapea cada variable con la cláusula que forzó su asignación, o *None* si fue por decisión. Estos funcionan como los “arcos” del grafo de decisión.
- *decision_level*: Guarda el nivel actual de decisión.
- *decision_stack*: Pila que registra el historial de asignaciones como tuplas: (variable, valor, nivel de decisión).

El bucle principal del algoritmo se encuentra en el método `solve(self)`. Mientras no se detecte un conflicto, asigna valores a variables no asignadas, actualizando las estructuras del solver. Si no quedan variables por asignar, devuelve la asignación completa y declara la fórmula como satisfacible. Si se detecta una cláusula conflicto y el nivel actual de decisión es 0, entonces devuelve *None*, declarando que la fórmula es insatisfacible.

El método `unit_propagate(self)` realiza propagación unitaria dentro de un ciclo de punto fijo que se repite mientras haya cambios (es decir, mientras existan cláusulas unitarias). Si se encuentra una cláusula conflicto, se detiene y la devuelve. Si no hay conflicto, retorna *None*. Para determinar el estado de una cláusula (*'satisfied'*, *'conflict'*, *'unit'*, *'undefined'*), se utiliza el método `check_clause(self, clause)`.

Cuando se detecta una cláusula conflicto, se invoca `conflict_analysis(self, conflict_clause)`. Este analiza cuántos literales de la cláusula conflicto fueron asignados en el nivel de decisión actual. La cláusula aprendida debe contener exactamente un literal asignado en ese nivel. Si hay más de uno, se identifica el último literal asignado (según el grafo de decisión), se busca la cláusula que causó su asignación y se aplica el Principio de Resolución entre ella y la cláusula aprendida. Este proceso se repite hasta obtener una cláusula con un solo literal en el nivel actual.

Luego, se determina el *backjump level*, es decir, el nivel de decisión más alto presente en los literales de la cláusula aprendida (distinto del actual). Si este nivel es 0,

CDCL considera la FNC como insatisfacible. Finalmente, se invoca el método *back-jump(self, level)* que deshace las asignaciones por encima del nivel objetivo y actualiza las estructuras correspondientes.

CDCL resuelve los problemas de búsquedas redundantes y *backtrack* cronológico de DPLL, sin embargo, aún deja pendientes por resolver problemas como la selección de variables.

1.3. Heurísticas

1.3.1. *Dynamic Largest Individual Sum* (DLIS)

La heurística *Dynamic Largest Individual Sum* es un método aproximado de selección de variables que busca hacer eficiente la selección de variables en un CDCL SAT *solver*. Para ello, DLIS considera que la próxima variable a asignar será aquella cuyo literal (el de mayor valor) tenga la mayor frecuencia de aparición en cláusulas insatisfechas. Es decir, para una variable x , se calcula la cantidad de cláusulas no satisfechas en las que aparece el literal x (forma positiva) y su complemento $\neg x$ (forma negativa). Denotemos:

- $count_pos(x)$: cantidad de veces que x aparece positivamente en cláusulas insatisfechas.
- $count_neg(x)$: cantidad de veces que $\neg x$ aparece en cláusulas insatisfechas.
- $dlis(x) = \max(count_pos(x), count_neg(x))$.

La próxima variable a seleccionar será aquella que maximice el valor de $dlis(x)$ entre todas las variables no asignadas:

$$x_k \mid dlis(x_k) = \max(dlis(x_i)), \quad i \in [1, n]$$

donde n es el total de variables de la FNC.

Obsérvese que si $count_pos(x_k) > count_neg(x_k)$, entonces se asigna a x_k el valor 1; en caso contrario, se asigna 0. El cálculo debe aplicarse solo a las variables no asignadas y solo considerar valores aún no explorados en el nivel actual de decisión.

Esta heurística busca satisfacer la mayor cantidad de cláusulas posibles en un mismo nivel de decisión.

Tomando como base el algoritmo Abrir código fuente, una forma de integrar DLIS sería como se muestra en Abrir código fuente. Esta estrategia de selección de variables puede integrarse en el algoritmo CDCL previamente presentado, sustituyendo la función `pick_branching_variable(self)` por una versión que implemente la heurística DLIS.

Las estructuras `pos_counts` y `neg_counts` se utilizan para almacenar, respectivamente, la cantidad de veces que el literal positivo y el literal negativo de cada variable no asignada aparece en las cláusulas actualmente insatisfechas. Este conteo es esencial para aplicar la heurística DLIS (*Dynamic Largest Individual Sum*) de forma efectiva.

El procedimiento comienza recorriendo todas las cláusulas de la fórmula. Por cada cláusula que no esté satisfecha, se inspeccionan sus literales, y se incrementa el contador correspondiente de cada literal no asignado. Por ejemplo, si un literal positivo x aparece en una cláusula insatisfecha, se incrementa `pos_counts[x]`, y si aparece su complemento $\neg x$, se incrementa `neg_counts[x]`.

Luego de este recorrido, se identifican todas las variables no asignadas que podrían no haber sido contadas, ya que podrían aparecer solamente en cláusulas ya satisfechas. A estas variables se les inicializa ambos contadores (positivo y negativo) en cero para garantizar una evaluación completa.

A continuación, se calcula el *score* para cada variable no asignada, definido como el máximo entre `pos_counts[x]` y `neg_counts[x]`. Este valor representa la cantidad máxima de cláusulas que podrían satisfacerse al asignarle a la variable el valor correspondiente. Las variables se ordenan según su *score* en orden descendente, y se elige aquella con el *score* más alto como la próxima variable a asignar. En caso de empate, se utilizan criterios secundarios como la suma total de apariciones y el índice de la variable.

El valor que se asigna a la variable seleccionada depende de cuál de los dos conteos es mayor. Si `pos_counts[x]` es mayor que `neg_counts[x]`, entonces se asigna el valor `True` (es decir, x), de lo contrario se asigna `False` (es decir, $\neg x$).

DLIS tiene como objetivo maximizar el número de cláusulas satisfechas con cada asignación, lo que en teoría podría reducir la cantidad total de decisiones requeridas para encontrar una solución o para detectar una contradicción. Sin embargo, su aplicación resulta costosa para instancias de gran tamaño, debido a que implica una revisión completa de todas las cláusulas insatisfechas en cada nivel de decisión. Esto conduce a una complejidad computacional de $O(n)$ por nivel, donde n es el número total de literales en la fórmula.

1.3.2. *Variable State Independent Decaying Sum (VSIDS)*

La heurística de selección de variables que plantea *Variable State Independent Decaying Sum* (VSIDS), prioriza asignar valores a aquellas variables que hayan estado involucrados en conflictos recientes. Para ello, VSIDS mantiene un *score* por variable que se incrementa cada vez que esta aparece en cláusulas aprendidas a partir de conflictos. Además, para evitar que variables involucradas en conflictos antiguos tengan mayor prioridad que los relacionados con conflictos recientes, cada cierta cantidad T de conflictos se actualizan los *scores* de todas las variables multiplicándolas por un

factor de “decaimiento” α , con $0 < \alpha < 1$ (usualmente $\alpha = 0,95$).

Tomando como base el ejemplo de implementación de CDCLAbrir código fuente, este sería el flujo de funcionamiento:

1. Se ejecuta el algoritmo CDCL.
2. Si ocurre un conflicto, se añade la cláusula aprendida $\mathbf{C}_{\text{learn}}$. Luego, para cada literal l en $\mathbf{C}_{\text{learn}}$, se actualiza su *score* con $\text{score}(l) = \text{score}(l) + \delta$, donde δ es un incremento positivo.
3. Si se alcanza el conflicto número T , se actualiza el incremento con $\delta = \delta \times \alpha$, con $0 < \alpha < 1$.
4. Si no ocurre un conflicto, se selecciona la variable v cuyo literal l_v cumple que su *score* es máximo entre todos los literales l_i , con $i = 1, 2, \dots, 2n$, siendo n la cantidad de variables. Si l_v es positivo, se asigna el valor 1 a v , y 0 en caso contrario.

El métodoAbrir código fuente selecciona, de entre las variables aún no asignadas, aquella con el mayor *score* de acuerdo con la estrategia VSIDS. Para implementar este comportamiento, se añade a la clase *SATSolver* una estructura llamada *activity*, la cual asocia a cada variable un valor numérico que representa su actividad o relevancia. Esta estructura se inicializa al comienzo de la ejecución inspeccionando todas las variables presentes en las cláusulas de la fórmula, como se muestra en `Graphics/dpll_cdcl_vsids_sat_solver.py`.

Durante la ejecución del algoritmo CDCL, la estructura *activity* se actualiza dentro del método *solve(self)*. En particular, cada vez que se detecta un conflicto y se aprende una nueva cláusula, se incrementa la actividad de todas las variables que aparecen en dicha cláusula. Además, para priorizar los conflictos más recientes, se aplica un factor de decaimiento a todas las variablesAbrir código fuente.

De este modo, la heurística VSIDS logra priorizar variables relevantes en conflictos recientes, mejorando la toma de decisiones del solucionador sin necesidad de reexaminar toda la fórmula.

Esta heurística está entre las más usadas en los CDCL SAT *solvers* modernos.

1.3.3. Reinicio (*restart*)

Las estrategias de *restart* tienen como objetivo evitar que el algoritmo de CDCL se estanque en regiones locales del espacio de búsqueda. Para ello, se permite reiniciar el árbol de decisiones, es decir, eliminar todas las asignaciones realizadas hasta el momento y comenzar nuevamente desde el nivel de decisión cero. Sin embargo, se conservan las cláusulas aprendidas durante el proceso, así como la información

acumulada por las heurísticas de selección de variables (por ejemplo, las actividades de las variables en VSIDS o los conteos en DLIS). Estas estrategias buscan que, al conservar el conocimiento adquirido (cláusulas aprendidas), el solucionador pueda explorar regiones más prometedoras del espacio de soluciones sin tener que recorrer nuevamente caminos improductivos.

Existen diversos criterios para decidir cuándo realizar un reinicio:

1. **Fijo:** se realiza un reinicio después de un número fijo k de conflictos. Esta es una estrategia sencilla pero poco adaptativa.
2. **Geométrico:** el número de conflictos entre reinicios crece de forma geométrica según la relación $r_0 = b$, $r_i = \alpha \cdot r_{i-1}$ con $\alpha > 1$. Esta estrategia permite reinicios más frecuentes al principio, reduciéndose con el tiempo. Un valor muy grande de α puede hacer que los reinicios sean demasiado esporádicos, mientras que un valor muy pequeño puede provocar una sobrecarga de reinicios.
3. **Luby:** utiliza la secuencia de Luby $(1, 1, 2, 1, 1, 2, 4, 1, 1, 2, \dots)$ para definir los intervalos entre reinicios, según la fórmula $r_i = b \cdot \text{Luby}(i)$, donde b es un parámetro base que define el tamaño mínimo del intervalo. Esta estrategia tiene fundamentos teóricos que justifican su uso en entornos donde no se conoce a priori una buena política de reinicio.
4. **Glucose-style (basada en LBD):** esta estrategia se basa en el cómputo de la medida *Literal Block Distance* (LBD) de las cláusulas aprendidas. Dada una cláusula C_{learn} , su LBD se define como el número de niveles de decisión distintos a los que pertenecen sus literales:

$$\text{LBD}(C_{learn}) = |\{\text{level}(l) \mid l \in C_{learn}\}|$$

La idea es que una cláusula con menor LBD involucra decisiones más cercanas entre sí, lo que la hace más relevante para guiar el proceso de resolución.

Para implementar esta estrategia, se mantienen dos promedios móviles de los LBD: uno para una ventana rápida de conflictos recientes (por ejemplo, los últimos 50 o 100) y otro para una ventana más larga (por ejemplo, los últimos 1000). Denotando estos promedios como μ_r (rápido) y μ_l (lento), se define un umbral $T > 1$. Si se cumple la condición:

$$\frac{\mu_r}{\mu_l} > T$$

entonces se considera que el solucionador está atrapado en una región poco productiva y se procede con un reinicio.

La incorporación de estrategias de reinicio, particularmente aquellas adaptativas como Luby o Glucose-style, ha demostrado ser fundamental para el éxito de solucionadores modernos de SAT, ya que permiten alternar entre exploración y explotación de manera eficiente en espacios de búsqueda complejos.

Ussando como base el código anterior Abrir código fuente de CDCL, una posible implementación para, por ejemplo, la estrategia Luby sería Abrir código fuente.

Como se puede ver en el código, Luby se ha integrado al algoritmo CDCL modificando su estructura de control de conflictos. Para ello, se define una función `luby(u, k)` que genera el k -ésimo valor de la secuencia de Luby multiplicado por una unidad base u , la cual determina el número de conflictos que deben ocurrir antes de realizar un reinicio.

Dentro de la clase principal del solucionador, se inicializan los siguientes parámetros:

- `unit_run`: intervalo base de conflictos entre reinicios.
- `luby_idx`: índice actual dentro de la secuencia de Luby.
- `conflicts_since_restart`: contador de conflictos desde el último reinicio.
- `next_restart`: umbral de conflictos para el siguiente reinicio, calculado como `luby(unit_run, luby_idx)`.

Durante la ejecución del método `solve()`, cada vez que se detecta un conflicto y se realiza el correspondiente análisis y retroceso (“*backjump*”), se incrementa el contador de conflictos. Luego, se verifica si el número acumulado de conflictos ha alcanzado el umbral definido por la secuencia de Luby. En caso afirmativo, se ejecuta un reinicio que implica:

- Vaciar las estructuras de asignaciones, niveles de decisión, razones de propagación y la pila de decisiones.
- Reiniciar el nivel de decisión a cero.
- Calcular el nuevo umbral de reinicio actualizando el índice de Luby y recalculando `next_restart`.
- Reiniciar el contador de conflictos desde el reinicio.

Cabe destacar que durante el reinicio no se eliminan las cláusulas aprendidas, lo cual permite conservar información valiosa obtenida en decisiones anteriores. Esta estrategia favorece la salida de áreas del espacio de búsqueda poco prometedoras,

maximizando la posibilidad de encontrar una solución en regiones más relevantes del espacio de soluciones.

A pesar de los avances, la separación teórica entre *solvers* CDCL con y sin reinicios continúa siendo una pregunta abierta relevante, dado que muchos resultados dependen intrínsecamente de los reinicios.

1.3.4. *Two Watched Literals (TWL)*

Una de las estrategias más empleadas en solucionadores modernos de SAT para optimizar la propagación unitaria es *Two Watched Literals (TWL)*. Esta técnica tiene como objetivo evitar el recorrido exhaustivo de todas las cláusulas en cada paso de propagación, mediante la vigilancia de dos literales por cláusula, denominados l_1 y l_2 .

Durante la ejecución del algoritmo, si ambos literales vigilados en una cláusula no han sido evaluados, o al menos uno de ellos tiene valor verdadero, entonces no es necesario revisar dicha cláusula, ya que no es unitaria ni entra en conflicto. En caso contrario, si uno de los literales es asignado a falso, se intenta buscar dentro de la cláusula otro literal que no haya sido evaluado o que tenga valor verdadero, con el fin de reemplazar al literal que fue asignado a falso. Si no se encuentra un reemplazo válido y el otro literal vigilado aún no tiene valor, entonces la cláusula se vuelve unitaria, forzando la asignación del segundo literal. Si ambos literales vigilados son evaluados a falso, la cláusula se considera en conflicto.

Esta estrategia resulta altamente eficiente, ya que disminuye considerablemente el número de cláusulas que deben revisarse en cada nivel de decisión, optimizando así el rendimiento del algoritmo CDCL.

Para integrar la estrategia TWL en el código base de CDCL, es necesario modificar la estructura interna del solucionador, incluyendo los métodos de propagación, asignación y retroceso, entre otros. El código de ejemplo es Abrir código fuente.

La implementación del algoritmo CDCL puede enriquecerse significativamente mediante la integración del esquema Two Watched Literals (TWL), el cual transforma de manera sustancial la manera en que se gestiona la propagación unitaria.

En la versión básica de CDCLAbrir código fuente, el procedimiento de propagación unitaria examina exhaustivamente todas las cláusulas de la fórmula para identificar aquellas que se reducen a una sola literal no asignada bajo la interpretación parcial actual. En contraste, el enfoque basado en TWL introduce una estructura auxiliar que asigna a cada cláusula exactamente dos literales que actúan como “vigilantes”. Mientras al menos uno de ellos no esté asignado a falso, se garantiza que la cláusula no puede causar conflicto ni ser unitaria, permitiendo así omitir su revisión durante la propagación.

El impacto de esta estrategia se observa en la estructura del código. En la implementación enriquecida, se incorpora un diccionario que mapea cada literal a una lista

de índices de cláusulas que lo están “observando”. Esta organización permite que, ante la asignación de un literal, solo se revisen aquellas cláusulas que lo tienen como vigilante, reduciendo de forma drástica la cantidad de cláusulas analizadas en cada nivel de decisión. Además, se redefine el procedimiento de propagación unitaria para que, al detectar que un literal vigilado ha sido evaluado a falso, se intente encontrar otro literal en la cláusula que pueda ocupar su lugar como nuevo vigilante. Si esto no es posible y el otro literal vigilado tampoco satisface la cláusula, se deduce que esta es unitaria o de conflicto, y se actúa en consecuencia.

Además de modificar la propagación unitaria, la estrategia TWL afecta también la gestión de cláusulas aprendidas. Cada vez que se genera una nueva cláusula como resultado del análisis de conflictos, se seleccionan dos de sus literales para ser vigilados y se actualizan las estructuras de observación en consecuencia. Esto asegura que las optimizaciones ofrecidas por TWL se mantengan vigentes incluso cuando la fórmula evoluciona durante la ejecución del algoritmo.

La transición desde un esquema de propagación unitaria tradicional hacia un enfoque basado en TWL representa una mejora sustancial en términos de eficiencia algorítmica. Al limitar el conjunto de cláusulas a inspeccionar en cada paso, se logra una aceleración significativa del proceso de inferencia, lo cual resulta especialmente beneficioso en instancias de gran escala, donde los costos de propagación pueden dominar el tiempo total de ejecución.

1.4. CaDiCaL

CaDiCaL es un *solver* SAT moderno implementado en C++ que combina claridad de diseño y eficiencia práctica. La arquitectura se organiza en un módulo interno, responsable de la búsqueda CDCL y de técnicas de simplificación de fórmulas; y en un módulo externo que actúa como fachada, gestiona la API y, en modo incremental, revierte pasos de *inprocessing* para mantener limpia la pila de reconstrucción.

1.4.1. Ramificación/on (selección de variables)

Las decisiones de ramificación se guían por heurísticas de actividad basadas en VSIDS, alternando entre fases estables y enfocadas para mejorar el rendimiento en instancias satisfacibles.

1.4.2. Políticas de reinicio

CaDiCaL implementa políticas de reinicio dinámicas que se ajustan al comportamiento interno del *solver*. Estos reinicios, permiten al solucionador escapar de subespacios improductivos sin perder las cláusulas aprendidas. Para ello, CaDiCaL emplea

políticas adaptativas que utilizan contadores de eventos (por ejemplo, accesos a memoria) en lugar de mediciones temporales directas, lo que garantiza determinismo entre ejecuciones. Estas políticas bloquean reinicios cuando la búsqueda se encuentra próxima a una solución potencial, siguiendo estrategias propuestas en la literatura. Todas las *restart policies* pueden ajustarse mediante múltiples parámetros para adaptarse a las características de cada instancia.

CaDiCaL alterna entre dos modos operativos principales: modo estable y modo enfocado. En el modo estable, se utilizan reinicios tipo Luby1.3.3 con un intervalo base elevado (1024 conflictos). Este modo promueve estabilidad, realiza retrocesos cronológicos y aplica la heurística VSIDS con bajo factor de incremento. Por otro lado, en el **modo enfocado**, se aplican reinicios como *Glucose-style*1.3.3 con intervalos cortos entre reinicios (2 conflictos).

1.4.3. *Assumptions*

Las *assumptions* permiten invocar un SAT *solver* con un conjunto de valores previamente asignados a ciertas variables. Esta funcionalidad resulta particularmente útil en contextos donde el *solver* se utiliza de manera iterativa.

Por ejemplo, si se requiere agregar o eliminar una cláusula c_i entre distintas invocaciones al *solver*, esta puede incorporarse a la fórmula como $(c_i \vee s_i)$, donde s_i es una variable de activación, selección o indicador. Al asignar $s_i = 1$, la cláusula c_i se incluye efectivamente en la fórmula; en cambio, al establecer $s_i = 0$, dicha cláusula se omite.

Esta técnica fue introducida originalmente en el *solver* MiniSat.

Además de su uso en la resolución incremental, las variables de activación también se aplican para representar cláusulas temporales. Por ejemplo, para incorporar una cláusula temporal c , se introduce una variable de activación a y se añade $(c \vee a)$ a la fórmula, bajo la suposición de $\neg a$. Para eliminar c , basta con agregar la cláusula unitaria (a) .

En versiones recientes, CaDiCaL ha incorporado el uso de *constraints*, que pueden simularse a través de *activation literals* en versiones anteriores.

El incremento en el número de variables de activación puede afectar negativamente el rendimiento del *solver*. Tradicionalmente, este inconveniente se ha abordado mediante reinicios periódicos.

Las *assumptions* se asignan y se propagan antes de que se inicie la búsqueda efectiva mediante la heurística de decisión de variables. Esta ordenación obedece a la arquitectura de los *solvers* CDCL (*Conflict-Driven Clause Learning*).

El algoritmo CDCL comienza con una fase de propagación unitaria. Si la PU detecta un conflicto en el nivel de decisión 0 (es decir, antes de que el *solver* haya realizado alguna decisión propia), se concluye que la fórmula, junto con las *assumptions* actua-

les, es insatisfacible. Esta verificación temprana resulta fundamental para la eficiencia del proceso, ya que permite detectar la insatisfacibilidad sin necesidad de explorar el espacio de búsqueda a través de decisiones de ramificación que, eventualmente, conducirían a un conflicto inevitable debido a los supuestos.

Solo si la PU no detecta conflictos y no todas las variables están asignadas, el *solver* procede a seleccionar una variable para ramificar, utilizando la heurística de decisión correspondiente.

Las *assumptions* constituyen un punto de partida para el *solver*. Estas se procesan inicialmente mediante la propagación unitaria, lo que permite verificar que la configuración inicial, incluyendo los supuestos, no conduzca a un conflicto inmediato. Esta estrategia optimiza el procedimiento, al evitar búsquedas infructuosas en regiones del espacio que se sabe de antemano que son inconsistentes con los supuestos proporcionados.

1.4.4. *Phasing*

La estrategia de *phasing* constituye un componente fundamental en los SAT *solvers* basados en CDCL, ya que desempeña un papel crucial en la guía del proceso de búsqueda de soluciones.

En el contexto de los *solvers* CDCL, una vez seleccionada una variable para ramificación, se debe decidir qué valor de verdad (también denominado *fase* o *polaridad*) asignarle. Esta decisión influye significativamente en la eficiencia del *solver*, particularmente en fórmulas satisfacibles.

La técnica de *phase saving* (ahorro de fases) consiste en registrar el último valor asignado a una variable (ya sea mediante decisión o propagación unitaria) y reutilizar este valor cuando la variable sea seleccionada nuevamente como variable de decisión. Esta técnica, sencilla y de bajo costo computacional, ha demostrado mejorar el rendimiento de forma notable y se ha convertido en un estándar en la mayoría de los *solvers* CDCL modernos. Se clasifica como una estrategia de intensificación, al mantener la búsqueda dentro de regiones previamente exploradas y potencialmente prometedoras.

Rephasing (refaseo) es una técnica de diversificación que complementa el ahorro de fases. Su propósito es reiniciar o ajustar la asignación parcial de las fases, permitiendo al *solver* explorar nuevas regiones del espacio de búsqueda. Dado que la selección de fase no compromete la corrección ni la terminación del algoritmo CDCL, las fases guardadas pueden modificarse arbitrariamente.

CaDiCaL incorpora mecanismos avanzados tanto de ahorro de fases como de *rephasing*. Ha sido pionero en la implementación de refaseo periódico, en el que los valores de fase se reinician en intervalos predefinidos durante la ejecución.

1.4.5. Modularidad y Extensibilidad del Código de CaDiCaL

La modularidad y la extensibilidad constituyen objetivos esenciales en el diseño de CaDiCaL. Este *solver* se ha convertido en plantilla para el “*hack track*” de la competencia SAT desde 2021, evidenciando su facilidad de adaptación. Los mecanismos principales para modificar su comportamiento incluyen:

- **API rica:** proporciona una interfaz en C++ (y limitada en C) que permite extender funcionalidades y personalizar la interacción con el solver.
- **Propagadores de usuario (ExternalPropagator):** habilita la implementación de propagadores externos capaces de importar y exportar cláusulas aprendidas o sugerir decisiones al solver, otorgando control directo sobre la búsqueda.
- **Estructura del código fuente:** el código, organizado de forma clara y modular, facilita su uso como modelo para portar e integrar técnicas de última generación en otros *solvers*.

Diversas investigaciones han extendido CaDiCaL para incorporar nuevas características, algunas de las cuales se han integrado en la versión oficial.

1.4.6. Ventajas de CaDiCaL para Experimentación

CaDiCaL resulta adecuado para estudios académicos sobre heurísticas y políticas de reinicio en SAT solving por las siguientes razones:

- **Diseño limpio y modular:** la arquitectura está orientada a la comprensibilidad y facilidad de modificación, lo que simplifica la implementación de nuevas estrategias sin la complejidad de otros solvers avanzados.
- **Flexibilidad en heurísticas y reinicios:** aunque dispone de configuraciones predeterminadas, permite alternar entre modos estable y enfocado, y ajustar esquemas de rephasing para probar variaciones en políticas de reinicio
- **Rendimiento competitivo:** mantiene un desempeño de última generación, garantizando que los resultados experimentales sean representativos del estado del arte.
- **Adopción en la comunidad:** su uso extendido en investigación genera un entorno colaborativo y recursos para investigadores.
- **Documentación exhaustiva:** el código fuente cuenta con comentarios detallados, facilitando la comprensión y manipulación del solver por parte de nuevos usuarios.

1.5. Parámetros de Evaluación para *solvers* CDCL: Taxonomía de extitBenchmarks

1.5.1. Categorías

La evaluación sistemática de solvers CDCL exige una taxonomía clara de instancias SAT que permita comparar heurísticas de actividad, estrategias de reinicio y métodos de propagación unitaria. Para este propósito, las instancias se clasifican según su origen y propiedades estructurales, de modo que cada categoría revele puntos fuertes y limitaciones algorítmicas extbf15,17.

En primer lugar, las instancias de aplicación proceden de problemas industriales, como la verificación de circuitos o la planificación logística. Estas fórmulas presentan estructuras modulares y *backdoors* pequeños (subconjuntos de variables cuya asignación simplifica significativamente la búsqueda), lo que permite a heurísticas dinámicas como VSIDS explotar patrones locales mediante el registro de conflictos recientes 20,21,23.

Por otro lado, las instancias combinatorias dificultosas, diseñadas para desafiar la generalidad de los solvers (por ejemplo, codificaciones del principio del palomar), carecen de la estructura implícita de los casos reales y exhiben simetrías y dependencias globales que ponen a prueba la adaptabilidad de las heurísticas 16,19.

Además, las instancias aleatorias, generadas según modelos Random k -SAT, muestran una distribución uniforme de cláusulas sin sesgos estructurales. En estas condiciones, técnicas como el aprendizaje de cláusulas ofrecen beneficios limitados, lo que resulta clave para evaluar el rendimiento en entornos carentes de regularidades extbf17,21.

1.5.2. Clasificación por Satisfacibilidad y Propiedades Estructurales

La distinción entre instancias SAT e UNSAT determina la orientación de las estrategias de resolución. En las primeras, las heurísticas que exploran asignaciones prometedoras (como VSIDS con preservación de fase (*phase saving*)) potencian la localización rápida de soluciones. Por su parte, las instancias UNSAT requieren la generación de cláusulas aprendidas de alto impacto, con el fin de acotar el espacio de búsqueda y acelerar la refutación 41.

Del mismo modo, las propiedades estructurales aportan criterios de evaluación adicionales. La modularidad de la fórmula y la existencia de *backbones* (variables que mantienen el mismo valor en todas las soluciones) facilitan la identificación de subespacios críticos.

1.5.3. Densidad y Transición de Fase

La densidad de una instancia, definida como el cociente entre cláusulas y variables, condiciona su nivel de dificultad. En los modelos aleatorios de 3-SAT, la complejidad alcanza su punto máximo alrededor de 4.26 cláusulas por variable, conocido como umbral de transición de fase **25**. En esta zona, heurísticas estáticas como DLIS pierden eficacia ante la ausencia de patrones explotables **17**. En cambio, la combinación de VSIDS con políticas de reinicio basadas en LBD equilibra la exploración global y la explotación local, permitiendo al *solver* superar con eficiencia estas regiones críticas **21**.

1.5.4. Relevancia para la Evaluación de Heurísticas

La selección de *benchmarks* resulta crucial al contrastar técnicas como VSIDS y DLIS. Mientras DLIS, basada en conteos estáticos de aparición de literales, ofrece un rendimiento óptimo en instancias aleatorias alejadas del umbral de transición de fase **18**, VSIDS prevalece en aplicaciones reales gracias a su adaptación dinámica a patrones de conflicto **30**.

1.6. Problemas

1.6.1. Random k -SAT

Los problemas Random k -SAT son un tipo de instancias generadas aleatoriamente que se utilizan ampliamente para evaluar y caracterizar el rendimiento de los algoritmos SAT. También se conocen como modelos de longitud fija de cláusula y constituyen un objeto de estudio prominente en la literatura.

En un problema Random k -SAT, se define un número de variables n , un número de cláusulas m y una longitud fija de cláusula k . Para generar cada cláusula, se seleccionan k literales de forma independiente y uniforme al azar del conjunto de posibles literales, que incluye las variables proposicionales y sus negaciones. No se incluyen cláusulas que contengan múltiples copias del mismo literal. El proceso de generación continúa hasta que la fórmula contiene el número total especificado de cláusulas m .

Una propiedad destacada del Random k -SAT es la presencia de un fenómeno de transición de fase. Este fenómeno se manifiesta como un cambio abrupto en la solubilidad al variar sistemáticamente el número de cláusulas m para un número fijo de variables n . Cuando m es pequeño, casi todas las fórmulas son poco restringidas y, por ende, satisfacibles. Al alcanzar un valor crítico m_c , la probabilidad de que una instancia sea satisfacible disminuye abruptamente hasta casi cero. Más allá de este punto, la

mayoría de las instancias se encuentran sobrerestringidas y son insatisfacibles. Para el caso de Random 3-SAT, esta transición ocurre aproximadamente cuando la razón cláusulas/variables (m/n) es cercana a 4.26 para valores grandes de n . La dificultad de los problemas SAT alcanza su punto máximo en esta región de transición.

1.6.2. Problema del palomar

El “problema del palomar” (*pigeonhole problem*) es una instancia de problema de Satisfacibilidad Booleana (SAT) que se ha convertido en un punto de referencia en la investigación de solvers SAT. A pesar de ser un problema combinatorio de tamaño relativamente pequeño, presenta dificultades particulares para los solvers CDCL (Conflict-Driven Clause Learning).

Este problema es un ejemplo de fórmulas “artesanales” o generadas aleatoriamente que resultan difíciles para los solvers CDCL. Se considera una de las clases de problemas para los cuales los solvers CDCL son “sin esperanza” en la demostración de insatisfacibilidad, dado que cualquier prueba de refutación por resolución requerirá un tamaño exponencial.

Este comportamiento contrasta con la eficiencia que muestran los solvers CDCL para problemas industriales o del mundo real. La dificultad radica en que los solvers CDCL no pueden generar pruebas de refutación sofisticadas de manera eficiente para este tipo de instancias, a diferencia de los problemas industriales donde sí pueden hacerlo.

El problema del palomar se usa como ejemplo para entender por qué los solvers CDCL son eficientes en muchas clases de instancias del mundo real, pero tienen un rendimiento pobre en instancias generadas aleatoriamente o criptográficas. La investigación se centra en comprender cómo las propiedades estructurales de las fórmulas se relacionan con la resolución SAT basada en CDCL.

1.6.3. Problema de coloreo de grafos

El problema de coloreado de grafos (GCP) es un concepto fundamental en informática y matemáticas, estrechamente relacionado con los Problemas de Satisfacción de Restricciones (CSP) y los Problemas de Satisfacibilidad Booleana (SAT).

GCP es una subclase importante dentro de los Problemas de Satisfacción de Restricciones (CSP). Su objetivo es asignar colores a los vértices de un grafo dado de modo que dos vértices conectados por una arista nunca compartan el mismo color. Un ejemplo sencillo de CSP es el coloreado de grafos, donde se busca que cada nodo adyacente tenga un color diferente. El problema de colorear la bandera canadiense es un ejemplo simple de coloreado de mapas, que a su vez es un caso particular del GCP.

Las instancias de coloreado de grafos con tres colores se cuentan entre los benchmarks más comúnmente usados para CSP.

La estrategia de “cold restart” FO (Forgetting Order), que consiste en reiniciar el solver olvidando el orden inicial de ramificación, ha demostrado ser especialmente adecuada para resolver instancias de la familia de problemas de coloreado.

1.6.4. XOR

El problema de paridad XOR es un área importante dentro de la Satisfacibilidad Booleana (SAT) y campos relacionados, especialmente en criptografía y teoría de códigos. Se refiere a un caso especial de los problemas XOR-SAT. Surge cuando las fórmulas booleanas se expresan como una conjunción de cláusulas donde la suma en \mathbb{F}_2 (base 2) se convierte en la operación lógica XOR (\oplus). Estas son comúnmente llamadas cláusulas XOR o cláusulas de chequeo de paridad.

1.6.5. *Bounded Model Checking* (BCM)

Bounded Model Checking (BCM) es un método de verificación de modelos simbólicos utilizado en la verificación formal de *hardware* y *software*. Es una técnica cada vez más aceptada en la industria para detectar una gama más amplia de errores, incluyendo condiciones de error sutiles, en comparación con las técnicas de validación tradicionales basadas en simulación.

En un enfoque BMC, se utilizan codificaciones en Forma Normal Conjuntiva (FNC) y algoritmos SAT estándar para encontrar errores de manera más rápida y de tamaño mínimo.

Instancias de problemas relacionados con BMC, como “hardware-bmc” y “hardware-bmc-ibm”, se han utilizado en competiciones SAT para evaluar el rendimiento de los solucionadores.

1.7. Ineficiencias Fundamentales de SAT

El enfoque de fuerza bruta para resolver SAT, es decir evaluar las 2^n asignaciones posibles mediante tablas veritativas, evidencia su carácter intratable en el peor de los casos **19**. Esta explosión combinatoria se intensifica en fórmulas que carecen de estructura discernible, en las cuales técnicas como la propagación unitaria o el aprendizaje de cláusulas presentan un impacto limitado **30**. En particular, las instancias aleatorias del problema 3-SAT próximas al umbral de fase (aproximadamente 4.26 cláusulas por variable **30**) provocan que algoritmos clásicos como DPLL experimenten un crecimiento exponencial en el tiempo de ejecución **27**.

No obstante, SAT se consolida como una herramienta práctica debido a dos factores principales: (1) la posibilidad de codificar CSPs genéricos en FNC; y (2) la existencia de solucionadores modernos basados en CDCL, los cuales aprovechan regularidades empíricas observadas en instancias industriales **3**. Esta dualidad entre complejidad teórica y eficiencia práctica posiciona a SAT como un componente central en aplicaciones como verificación de hardware, planificación autónoma y criptoanálisis **39**.

chapterPropuesta

Capítulo 2

Detalles de Implementación y Experimentos

El objetivo de esta tesis es comparar dos de las heurísticas integradas a CDCL, en este caso, dos de las que intentan dar solución al problema de selección de variables: Dichas estrategias, VSIDS y DLIS, son comparadas usando *restart* y no.

En el trabajo se usaron los lenguajes de programación C++, Python y bash. CaDiCaL está programado en C++, por lo que es el lenguaje en el que están implementadas las heurísticas. Python fue usado para automatizar los procesos de pruebas, guardar los resultados obtenidos y realizar los análisis estadísticos. Finalmente, bash se usa como parte de la compilación del solver, cuyos archivos como *configure* y *makefile* que vienen integrados al *solver*, son los encargados de hacerlo funcionar.

2.0.1. CaDiCaL

CaDiCaL fue el *solver* escogido para esta comparación, ya que cuenta con la posibilidad de activar y desactivar VSIDS (ya viene integrada), al igual que la estrategia *restart*, también integrada en el solucionador.¹ Como ya se mencionó con anterioridad en este documento, prácticamente todos los CDCL SAT *solvers* modernos no incluyen DLIS como heurística de selección de variables, y CaDiCaL es uno de ellos. Por esta razón, se decidió integrar una implementación de DLIS a este solucionador, aprovechando la política *open source* de su código fuente.

¹Cabe destacar que CaDiCaL ofrece esta misma posibilidad para muchas heurísticas, además de estrategias para adaptar la vía de solución al tipo de problemas (citar documentación de CaDiCaL)

Integración de DLIS

Para integrar DLIS en CaDiCaL se modificaron los siguientes archivos:

- *internal.hpp*
- *internal.cpp*
- *decide.cpp*
- *options.hpp*

internal.hpp En este archivo se declaran los métodos que serán implementados como parte de la clase *Internal*:

```
// DLIS
int next_decision_variable_with_dlis ();
int count_literal_in_unsatisfied_binary_clauses(int lit)
    ;
```

internal.cpp En *internal.cpp* se añade el siguiente código que contiene la lógica de funcionamiento de DLIS. CaDiCaL almacena las variables de la FNC en una lista doblemente enlazada, en la que aquellas que ya han sido asignadas y las que aún no tienen un valor definido se encuentran separadas en dos grupos (dentro de la misma lista) separadas por un índice que marca el límite entre ellas. Este valor va cambiando con cada asignación. Haciendo uso de esta estructura, el siguiente método se encarga de comparar la ocurrencia, en cláusulas insatisfechas, de los literales correspondientes a las variables sin asignar, y elige el de valor máximo.

```
int Internal::next_decision_variable_with_dlis () {
    int best_lit = 0;
    int best_score = -1;

    // Empezamos en el primer nodo "no asignado" de la
    // cola:
    int idx = queue.unassigned;

    // Recorremos la lista de variables sin asignar (link(
    // idx).prev nos lleva
    // al siguiente "sin asignar"), igual que en
    // next_decision_variable_on_queue().
    while (idx) {
        // Si idx ya tiene val(idx) != 0, saltamos (aunque en
        // teoría queue.unassigned
```

```

    // siempre apunta a un idx tal que val(idx)==0; no
    // obstante, por seguridad lo comprobamos).
    if (val(idx) == 0) {
        // Calcular la puntuaci\on DLIS para +idx y para -
        // idx
        int pos_score =
            count_literal_in_unsatisfied_clauses_(idx);
        int neg_score =
            count_literal_in_unsatisfied_clauses_(-idx);

        float med_score = (pos_score + neg_score)/2; // Se
            // toma el promedio por la estrategia de phase

        // Comparar con el mejor hasta ahora
        if (med_score > best_score) {
            best_score = med_score;
            best_lit    = idx;
        }
    }
    // Avanzamos al siguiente \indice ‘‘no asignado’’:
    idx = link(idx).prev;
}

LOG ("next DLIS decision literal %d with score %d",
    best_lit, best_score);
return abs(best_lit);
}

```

Es importante aclarar que el cálculo del *score* de cada literal no se hace tal cual dicta DLIS, pues en aras de mantener la consistencia del código de CaDiCaL se usaron estrategias y estructuras que ya vienen implementadas, y a las cuales se acoplan las heurísticas de decisión de variables que ya incorpora el solucionador. En este caso, obsérvese que se promedian los *scores* de ambos literales. Esto, debido a que CaDiCaL implementa la estrategia *phase* (citar info en marco teórico) para elegir la polaridad de la variable. Por esta razón el método devuelve la variable y no el literal.

Obsérvese que este método hace un llamado a

```
int count_literal_in_unsatisfied_clauses_(idx)
```

que es el encargado de calcular el *score* para un literal.

```
int Internal::count_literal_in_unsatisfied_clauses_ (int
    lit) {
```

```

int count = 0;
// Cacheamos una sola vez el valor de 'lit'.
const signed char val_lit = val (lit);
// Recorremos su lista de watchers
const Watches &ws = watches (lit);
for (const Watch &w : ws) {
    Clause *c = w.clause;
    if (!c || c->garbage) continue;           // Saltar nulos y
        garbage
    int other = w.blit;                       // El otro
        literal de la cl\'ausula
    // Si 'lit' o 'other' ya son verdaderos, la cl\'ausula
        est\'a satisfecha
    if (val_lit != 0 || val (other) != 0) continue;
    ++count;
}
return count;
}

int Internal::compute_dlis_score(int lit) {
    return count_literal_in_unsatisfied_clauses_(lit);
}

```

En el código anterior puede verse que para efectuar el conteo de ocurrencias de un literal no se revisan todas las cláusulas insatisfechas; en su lugar se aprovecha la estructura que usa CaDiCaL para aplicar la estrategia *Two Watched Literals* (TWL) (hacer referencia al marco teórico). Luego, se recorren solo las cláusulas insatisfechas donde el literal esté vigilado, y se procede con el cálculo de su *score*. Con esta implementación se busca disminuir para algunos problemas el costo de recorrer todas las cláusulas.

decide.cpp

El flujo de decisión sobre la próxima variable a asignar se lleva a cabo en el archivo *decide.cpp*, específicamente en el siguiente método:

```

int Internal::decide () {
    assert (!satisfied ());
    START (decide);
    int res = 0;

    //... implementacion de assumptions

```

```

else {

    int decision = 0;
    int idx = 0;

    if (opts.dlis /*&& stats.decisions < threshold*/) {
        //decision = pick_dlis_branch_literal();
        idx = next_decision_variable_with_dlis ();
        LOG ("DLIS decision literal %d", decision);
    } else {
        idx = next_decision_variable ();
    }
    const bool target = (opts.target > 1 || (stable &&
        opts.target));
    if (idx) decision = decide_phase (idx, target);

    if (decision) {
        stats.decisions++;
        LOG ("deciding literal %d", decision);
        search_assume_decision (decision);
    }
}

if (res) marked_failed = false;
STOP (decide);
return res;
}

```

Como se puede observar, se respeta el orden de decisión que sigue CaDiCaL, garantizando primero el análisis de los valores de las variables según *assumption* ((assumptions→hacer referencia a donde se explican en el marco teórico). Luego, antes de aplicar DLIS se verifica si su flag correspondiente está activada (DLIS no se usa por defecto), y en caso positivo se procede con la elección de la variable según lo explicado anteriormente. Obsérvese también que heurísticas las heurísticas de decisión de variables implementadas en el *solver* se analizan luego de *assumptions*.

Una vez escogida la variable, se llama al método *decide_phase* para elegir su polaridad en base a la estrategia *phasing* (citar phasing en el marco teórico).

options.hpp

Finalmente, para habilitar la *flag* `-dlis=<bool>` para activar y desactivar la heurística incorporada, se añadió la siguiente línea al archivo *options.hpp*

```
#define OPTIONS \
\
/*      NAME      DEFAULT, LO, HI, O, P, R,  USAGE */ \
\
//... varias options...
OPTION( dlis,          0,   0,   1, 0, 0, 1,  "use DLIS
      decision heuristic") \
//... varias options...
```

2.0.2. Empleo de *flags* en la l/ínea de comandos

Los *flags* usados en la l/ínea de comandos para combinar las heurísticas fueron:

- VSIDS + restart = `-score=false`
- VSIDS + no restart = `-score=false -restart=false`
- DLIS + restart = `-dlis=true -score=false`
- DLIS + no restart = `-dlis=true -score=false -restart=false`

La *flag* `-score=false` desactiva el empleo de la estrategia EVSIDS (citar en el marco teórico) para usar solo el *bump* característico de VSIDS. El resto de las que están son bastante descriptivas. Fueron usadas, además, dos *flags* generales para cada heurística: `-t 120` que pone un *timeout* de máximo 120 segundos, y `-stats` que muestra estadísticas extra para los problemas resueltos (resultado = *SATISFIABLE/UNSATISFIABLE*).

2.0.3. Problemas

Cada combinación de heurística fue probada en cada uno de los 135 problemas generados que abarcan las siguientes categorías:

- Random 3-SAT
 - Se generaron 15 instancias.
 - Tamaños de variables: 1000, 2000, 5000 (rotando cíclicamente).
 - Relación cláusulas/variables: 3.76, 4.26 y 4.76 (alrededor del umbral de fase para 3-SAT).

- Ejemplo de archivo: random3sat_n1000_r4.26_0.cnf.
- *Pigeonhole Principle* (principio del palomar)
 - Se generaron 15 instancias.
 - Número de hoyos: 10, 20, 30, 40, 50 (rotando cíclicamente).
 - Número de palomas: siempre $n_hoyos + 1$.
 - Ejemplo de archivo: pigeon_11_into_10_0.cnf.
- Random 4-SAT
 - Se generaron 15 instancias.
 - Tamaños de variables: 500, 1000, 2000 (rotando cíclicamente).
 - Relación cláusulas/variables: 8.88, 9.88, 10.88 (alrededor del umbral de fase para 4-SAT).
 - Ejemplo de archivo: random4sat_n500_r9.88_0.cnf.
- *Graph Coloring* en Grafos Aleatorios
 - Se generaron 10 instancias.
 - Número de nodos: 50, 100, 200 (rotando cíclicamente).
 - Probabilidad de arista: 0.1, 0.3, 0.5 (rotando cíclicamente).
 - Número de colores: 3, 4, 5 (rotando cíclicamente).
 - Ejemplo de archivo: graphcol_n50_p0.10_k3_0.cnf.
- *Parity (XOR) Constraints*
 - Se generaron 10 instancias.
 - Número de variables: 10, 20, 30, 40, 50 (rotando cíclicamente).
 - Ejemplo de archivo: parity_n10_0.cnf.
- BMC de Flip-Flop Simple
 - Se generaron 10 instancias.
 - Profundidad del circuito: 3, 5, 7, 9, 11 (rotando cíclicamente).
 - Ejemplo de archivo: bmc_flipflop_d3_0.cnf.
- Problemas *DLIS-friendly*
 - Se generaron 30 instancias.

- Número de variables: 200, 300, 400 (seleccionado aleatoriamente).
 - Tamaño de cláusula: 5 o 6 (aleatorio).
 - Relación cláusulas/variables: valor real entre 2.0 y 3.5 (aleatorio).
 - Sesgo positivo en literales: entre 0.7 y 0.8 (aleatorio).
 - Ejemplo de archivo: `biased_random5sat_n200_r2.45_b0.73_2000.cnf`.
- Problemas *no DLIS-friendly*
- Se generaron 30 instancias.
 - Número de variables: 1000, 2000, 5000 (aleatorio).
 - Tamaño de cláusula: 3.
 - Relación cláusulas/variables: valor real entre 4.0 y 5.0 (aleatorio).
 - Sin sesgo en literales: `bias_pos = 0.5`.
 - Ejemplo de archivo: `biased_random3sat_n1000_r4.32_b0.50_3000.cnf`.

El generador cubre exhaustivamente ocho familias de problemas: Random 3-SAT, *Pigeonhole*, Random 4-SAT, *Graph Coloring*, *Parity*, BMC Flip-Flop, *DLIS-friendly* y *no DLIS-friendly*. Cada familia tiene parámetros clave que varían (número de variables, relación cláusulas/variables, sesgo, tamaño de cláusula, profundidad, etc.), asegurando diversidad estructural y de dificultad en los *benchmarks* generados.

2.0.4. Generador de problemas

El generador de problemas (*benchmarks*) se programó en python y se usaron las bibliotecas *os*, *random* y *csv*. Los resultados se exportaron a una carpeta “*generated_benchmarks*” en el mismo directorio del *script* cuyos archivos se encuentran en formato DIMACS (referencia al marco teórico) en `.cnf`.

2.0.5. Estadísticas

El análisis estadístico de los resultados de la comparación de cada heurística por problema está implementado en el archivo *stats_analysis.ipynb*. Se comparó los problemas cuyo resultado fue *TIMEOUT* con los que sí resolvieron las heurísticas. Se hace un análisis de la distribución de cada característica en problemas *TIMEOUT* por heurística. Para el caso de los problemas resueltos (resultado = *SATISFIABLE/UNSATISFIABLE*) se hace de igual modo un análisis de la distribución y se incluye la característica *tiempo en segundos*. Posteriormente se hace un análisis comparativo entre los problemas que fueron resueltos y los que no. Para ello se realiza un análisis entre variables y se eliminan aquellas que sean colineales. Esta comprobación se

realiza mediante el cálculo del Factor de Inflación de Varianza (VIF). Para realizar la comparación en cuanto a características entre los problemas resueltos y los que no, se realizan las pruebas de Mann-Whitney U, y para visualizar los resultados se emplean gráficas de caja y bigotes. Además, también se usa regresión logística ya que permite interpretar cómo cada variable afecta la probabilidad de que ocurra o no un *TIMEOUT*.

La otra parte de la evaluación consiste en un análisis del rendimiento de cada combinación de heurísticas en cuanto al tiempo de ejecución en los problemas resueltos. Para ello se hizo un análisis de la correlación de Spearman entre las características de los problemas y el tiempo en segundos. Se realizó, además, el test de Kruskal-Wallis para analizar si el tiempo difiere entre heurísticas para un mismo tipo de problema. Asimismo, se realizó el test de Dunn por cada heurística para realizar una comparación estadística post-hoc (prueba de Dunn) para analizar si existen diferencias significativas en los tiempos de resolución ($\log(\text{tiempo})$) de una heurística específica en los problemas resueltos, según los valores de una característica. Los resultados son graficados en *boxplot*. Finalmente, se realiza una regresión lineal múltiple para definir qué características predicen el tiempo de resolución.

Para la implementación de estos análisis se usaron las siguientes bibliotecas de python: *pandas*, *numpy*, *seaborn*, *matplotlib.pyplot*, *statsmodels.api*, *variance_inflation_factor* y *variance_inflation_factor*, ambas de *statsmodels.stats.outliers_influence*, *ols* de *statsmodels.formula.api*, *scipy.stats*, *LogisticRegression* de *sklearn.linear_model*, y *scikit_posthocs*.

2.1. Resultados

2.1.1. Análisis de los problemas con TIMEOUT

Tabla resumen de TIMEOUTs

En la tabla (insertar referencia) se muestran las características de los problemas cuyo resultado fue timeout además del nombre de dicho problema y la heurística. (visualizar estos datos mediante graficas)

Con base en el conjunto de resultados filtrados por TIMEOUT, se observa que las heurísticas evaluadas presentan diferencias claras en su comportamiento frente a instancias con distintas características estructurales. Por ejemplo, la heurística VSIDS combinada con reinicio tiende a experimentar TIMEOUT en instancias con menor número de variables pero con una densidad relativamente alta de cláusulas por variable, lo que sugiere que esta configuración puede ser menos efectiva en problemas más densos aunque de tamaño moderado.

En contraste, DLIS sin reinicio acumula TIMEOUT en instancias con un mayor número de variables pero con densidad menor, indicando que esta heurística pue-

de tener dificultades para escalar en problemas más grandes, aunque menos densos. Además, la presencia o ausencia de reinicios parece influir significativamente en el rendimiento, dado que las combinaciones con reinicio generalmente muestran un patrón distinto de TIMEOUT frente a las que no lo incorporan.

Estas observaciones permiten suponer que la elección de heurística y estrategia de reinicio debe adaptarse a la estructura específica del problema SAT para optimizar el rendimiento y evitar fallos por límite de tiempo.

Estadísticas descriptivas

(insertar graficas boxplot)

El análisis estadístico descriptivo y las visualizaciones mediante diagramas de caja permiten observar con mayor detalle cómo se distribuyen las características de las instancias que resultaron en TIMEOUT según la heurística aplicada. En términos generales, las cuatro heurísticas (DLIS+no-restart, DLIS+restart, VSIDS+no-restart y VSIDS+restart) presentan distribuciones muy similares en cuanto a las métricas de número de variables, número de cláusulas, densidad, tamaño promedio de cláusula y cantidad de variables positivas y negativas.

Asimismo, la densidad media se mantiene cercana a 7.4–7.7 para todas las heurísticas, con una dispersión considerable que alcanza hasta 25, lo que refleja que tanto problemas poco densos como muy densos pueden provocar fallos por tiempo.

El tamaño promedio de cláusula se mantiene estable alrededor de 3, con poca variabilidad, sugiriendo que esta característica no discrimina el comportamiento de las heurísticas en cuanto a TIMEOUT.

Las variables positivas y negativas también muestran simetría y valores medios similares entre heurísticas, lo que implica que la polaridad de las variables no es un factor determinante en la ocurrencia de TIMEOUT.

En conjunto, estos resultados sugieren que las diferencias en el rendimiento entre heurísticas no se explican fácilmente por las características básicas de las instancias con TIMEOUT.

Las visualizaciones de caja refuerzan esta interpretación al mostrar solapamientos amplios en las distribuciones de cada característica por heurística.

Conteo de TIMEOUT por heurística y por problema

(insertar gráficas) En las graficas se puede observar que los problemas que tomaron mas tiempo en resolverse coinciden con los los planteados en la literatura que resultan mas dificiles de resolver a instancias SAT. Respecto a la cantidad de problemas con TIMEOUTS por heuristica, se puede apreciar que DLIS, independientemente del restart, se comporta mas lento que vsids para algunos problemas. Por su parte, vsids con restart se comporta mas lento que vsids sin restart para unas pocas instancias.

2.1.2. Análisis de problemas resueltos (SATISFIABLE/UN-SATISFIABLE)

Tabla resumen de RESUELTOS

(insertar grafico que describa los resultados de la tabla filtrada por problemas resueltos)

El análisis de los problemas resueltos muestra que las instancias que concluyeron satisfactoriamente (ya sea SATISFIABLE o UNSATISFIABLE) abarcan un amplio rango de tamaños y características, desde problemas muy pequeños con 6 variables y 12 cláusulas hasta otros considerablemente más grandes con hasta 5000 variables y más de 23000 cláusulas.

Los tiempos de resolución registrados varían notablemente, desde fracciones de segundo en problemas pequeños (por ejemplo, alrededor de 0.0014 segundos en instancias con 6 variables) hasta varios segundos en problemas más complejos (por ejemplo, cerca de 9 segundos en instancias con 500 variables y alta densidad). Esto indica que, aunque el solver puede resolver eficientemente instancias pequeñas o medianas, el tiempo de cómputo crece conforme aumentan la cantidad de variables y cláusulas, así como la densidad del problema.

La presencia de las cuatro heurísticas en los resultados resueltos sugiere que todas son capaces de resolver ciertos conjuntos de problemas. Sin embargo, la diversidad en tiempos y tamaños sugiere que la heurística y la estrategia de reinicio podrían influir en la eficiencia, especialmente en problemas de mayor escala.

Estadísticas descriptivas

(insertar gráfica boxplot)

El análisis estadístico descriptivo del tiempo de resolución y las características de las instancias resueltas por cada heurística revela patrones importantes sobre el comportamiento del *solver*.

En primer lugar, se observa que las instancias resueltas por las cuatro heurísticas (DLIS+no-restart, DLIS+restart, VSIDS+no-restart y VSIDS+restart) cubren un rango amplio en tamaño, con número de variables promedio entre 322 y 403, y máximos que alcanzan hasta 2000 o incluso 5000 variables en el caso de VSIDS+restart. La cantidad de cláusulas también presenta gran dispersión, con medias cercanas a 3100–3400 y máximos que superan las 50,000, lo que indica que el solver puede manejar problemas desde muy pequeños hasta instancias complejas. La densidad promedio se mantiene alrededor de 7,2 a 7,4, con valores máximos muy altos (hasta 51.9), reflejando diversidad en la estructura de los problemas.

En cuanto al tiempo de resolución, se evidencia una marcada diferencia entre heurísticas: DLIS+no-restart presenta el tiempo medio más bajo (0.37 s), seguido por

DLIS+restart (3.13 s), mientras que VSIDS+no-restart y VSIDS+restart muestran tiempos medios más elevados, cerca de 4.98 y 4.98 segundos respectivamente, con alta variabilidad (desviaciones estándar muy grandes y máximos que superan los 80 segundos). Esta dispersión sugiere que aunque VSIDS puede ser eficiente en muchos casos, también enfrenta problemas que requieren tiempos significativamente mayores. Además, la mediana del tiempo para todas las heurísticas es muy baja (en el orden de milisegundos), indicando que la mayoría de las instancias se resuelven rápidamente, pero existen casos atípicos que prolongan el tiempo promedio.

El tamaño promedio de cláusula es similar entre heurísticas, alrededor de 3.4, y las variables positivas y negativas mantienen valores simétricos, lo que indica que estas características no explican las diferencias en tiempo.

En conjunto, estos resultados sugieren que la elección de heurística impacta significativamente el tiempo de resolución en ciertos problemas, especialmente en instancias grandes o complejas, y que VSIDS puede tener mayor variabilidad en rendimiento.

2.1.3. Problemas RESUELTOS vs TIMEOUT

Análisis de multicolinealidad

(insertar matriz de correlación)

Como se puede apreciar, entre las variables `num_vars` y `vars_positivas` y `vars_negativas`, existe correlación perfecta ($r = 1$). Además, existe una correlación moderada entre las variables `num_clausulas` con `vars_negativas`, `vars_positivas`, `num_vars` y `densidad`). Luego, es necesario reducir el conjunto de características, quedando el siguiente: `caracteristicas_reducidas = ['num_vars', 'densidad', 'tamano_prom_clausula']`.

(insertar matriz de correlacion del nuevo conjunto) Como se muestra en la matriz, se eliminó las correlaciones moderadas y severas.

Comparación de características entre RESUELTOS Y TIMEOUTs

Al realizar el test de normalidad de Shapiro-Wilk se obtuvo los siguientes resultados:

```
num_vars (TIMEOUT): ShapiroResult(statistic=np.float64(0.7933191376191727),
pvalue=np.float64(1.1794648547679767e-18)) num_vars (NO TIMEOUT): ShapiroResult(sta
pvalue=np.float64(9.428437191286474e-26)) densidad (TIMEOUT): ShapiroResult(statist
pvalue=np.float64(7.820027948180053e-24)) densidad (NO TIMEOUT): ShapiroResult(stat
pvalue=np.float64(2.297890446301959e-29)) tamano_prom_clausula (TIMEOUT):
ShapiroResult(statistic=np.float64(0.752042266567243), pvalue=np.float64(2.48040464
tamano_prom_clausula (NO TIMEOUT): ShapiroResult(statistic=np.float64(0.8112114166
pvalue=np.float64(4.389991714803694e-20))
```

Este análisis revela que ninguna de estas características sigue una distribución normal en los grupos de instancias que terminaron en TIMEOUT ni en las que fueron resueltas. Esto se evidencia en los valores de p muy bajos (todos menores a 0.05, incluso extremadamente cercanos a cero), lo que permite rechazar la hipótesis nula de normalidad para cada variable en ambos grupos. En concreto, los estadísticos de Shapiro oscilan entre aproximadamente 0.54 y 0.81, y los p -valores indican una desviación significativa de la normalidad.

Luego, para comparar estas características entre instancias con y sin TIMEOUT no es apropiado utilizar pruebas paramétricas basadas en la normalidad, como el t -test, sino que se deben emplear métodos no paramétricos, por ejemplo la prueba de Mann-Whitney, cuyo resultado se presenta a continuación.

Prueba Mann-Whitney U

Mann-Whitney U para num_vars: p -value = 1.383e-83 Mann-Whitney U para densidad: p -value = 3.168e-29 Mann-Whitney U para tamaño_prom_clausula: p -value = 0.803

La prueba muestra resultados concluyentes sobre las diferencias entre las instancias que terminaron en TIMEOUT y las que fueron resueltas.

Para las variables número de variables y densidad, los valores p son extremadamente bajos (1.383e-83 y 3.168e-29 respectivamente), lo que indica diferencias estadísticamente significativas entre ambos grupos en estas características. Esto sugiere que tanto el tamaño del problema como su densidad influyen fuertemente en la probabilidad de que un problema termine en TIMEOUT.

En contraste, para el tamaño promedio de cláusula el p -valor es alto (0.803), lo que implica que no hay evidencia suficiente para afirmar que esta característica difiera entre problemas con y sin TIMEOUT.

Estos resultados confirman que las variables relacionadas con la escala y complejidad estructural del problema (num_vars y densidad) son factores determinantes en el rendimiento del solver, mientras que el tamaño promedio de las cláusulas no parece ser un factor discriminante en la ocurrencia de TIMEOUT.

En consecuencia, para modelar o predecir la probabilidad de TIMEOUT conviene priorizar las variables num_vars y densidad, y descartar o tratar con menor peso el tamaño promedio de cláusula.

Regresión logística: ¿Qué características predicen TIMEOUT?

Tras efectuar la regresión se obtuvieron los siguientes resultados:

num_vars: coeficiente logit = 0.0032 densidad: coeficiente logit = -0.0314
tamaño_prom_clausula: coeficiente logit = -0.5455

Con base en estos resultados, el modelo ofrece una interpretación clara sobre la influencia de cada característica en la probabilidad de que un problema no se resuelva en el tiempo límite.

El coeficiente positivo para `num_vars` (0.0032) indica que a medida que aumenta el número de variables, la probabilidad de TIMEOUT también incrementa, lo cual es consistente con la intuición y los análisis descriptivos previos que mostraron que problemas más grandes tienden a ser más difíciles de resolver.

Por otro lado, los coeficientes negativos para `densidad` (-0.0314) y especialmente para `tamaño promedio de cláusula` (-0.5455) sugieren que, manteniendo constante el número de variables, un aumento en estas características está asociado con una menor probabilidad de TIMEOUT. En particular, el `tamaño promedio de cláusula` tiene un efecto considerablemente más fuerte en sentido negativo, lo que podría indicar que cláusulas más largas o complejas, dentro del rango observado, facilitan la resolución o están asociadas a problemas menos propensos a agotar el tiempo.

Estos signos y magnitudes reflejan que la complejidad estructural del problema no se reduce solo al tamaño, sino que la forma en que las cláusulas están construidas también impacta el rendimiento del solver. En conjunto, el modelo confirma y cuantifica las tendencias observadas en análisis estadísticos previos, y ofrece una base para predecir y ajustar heurísticas en función de las características del problema para minimizar la ocurrencia de TIMEOUT.

2.1.4. Rendimiento de las heurísticas en problemas resueltos

Para los análisis estadísticos en esta sección se incluyó la variable `tiempo`, que indica en segundos cuánto tardó el *solver* en dar una solución.

Correlación de Spearman

Se obtuvo los siguientes resultados:

```
Spearman num_vars vs tiempo_segundos: rho = 0.845, p = 1.116e-63
Spearman densidad vs tiempo_segundos: rho = 0.318, p = 8.968e-07
Spearman tamaño_prom_claus vs tiempo_segundos: rho = 0.710, p = 1.929e-36
```

Este análisis revela asociaciones significativas y de distinta intensidad.

La variable `número de variables` muestra una correlación muy fuerte y positiva con el tiempo de resolución ($\rho = 0.845$, $p < 0.001$), indicando que a mayor tamaño del problema, mayor es el tiempo requerido para resolverlo, lo cual es coherente con la complejidad esperada en problemas SAT.

La `densidad` presenta una correlación positiva moderada ($\rho = 0.318$, $p < 0.001$), lo que sugiere que problemas con mayor densidad de cláusulas por variable tienden a requerir más tiempo, aunque este efecto es menos pronunciado que el del tamaño.

Por último, el tamaño promedio de cláusula también exhibe una correlación fuerte positiva ($\rho = 0.710$, $p < 0.001$), indicando que cláusulas más largas o complejas están asociadas con un aumento significativo en el tiempo de resolución.

Estos resultados confirman que tanto la escala del problema como su estructura influyen en el rendimiento del solver, siendo el número de variables el factor más determinante, seguido por la complejidad de las cláusulas y la densidad.

Kruskal-Wallis: ¿El tiempo difiere entre heurísticas para un mismo tipo de problema?

Dados los siguientes resultados:

Kruskal-Wallis para heurística: VSIDS+restart Variable: num_vars, estadístico = 55.0704, p-valor = $1.738e-06$ Variable: densidad, estadístico = 55.8711, p-valor = $8.922e-05$ Variable: tamaño_prom_clausula, estadístico = 54.8239, p-valor = 0.0001258

Kruskal-Wallis para heurística: VSIDS+no-restart Variable: num_vars, estadístico = 54.7791, p-valor = $9.448e-07$ Variable: densidad, estadístico = 55.2582, p-valor = $6.482e-05$ Variable: tamaño_prom_clausula, estadístico = 55.6763, p-valor = $9.513e-05$

Kruskal-Wallis para heurística: DLIS+restart Variable: num_vars, estadístico = 41.2553, p-valor = $4.441e-05$ Variable: densidad, estadístico = 40.6674, p-valor = 0.001692 Variable: tamaño_prom_clausula, estadístico = 42.9055, p-valor = 0.003232

Kruskal-Wallis para heurística: DLIS+no-restart Variable: num_vars, estadístico = 46.9197, p-valor = $4.813e-06$ Variable: densidad, estadístico = 47.8132, p-valor = $9.17e-05$ Variable: tamaño_prom_clausula, estadístico = 48.7640, p-valor = 0.000332

Se tiene que El análisis mediante la prueba no paramétrica de Kruskal-Wallis aplicado a la variable transformada del tiempo de resolución (logaritmo natural del tiempo más uno) para cada heurística y característica del problema revela diferencias estadísticamente significativas en todos los casos evaluados.

Para las cuatro heurísticas (VSIDS+restart, VSIDS+no-restart, DLIS+restart y DLIS+no-restart), las variables número de variables, densidad y tamaño promedio de cláusula muestran valores de estadístico elevados y p-valores muy bajos (todos menores a 0.005), lo que indica que la distribución del tiempo de resolución difiere significativamente entre los distintos grupos definidos por cada una de estas características. Esto implica que, independientemente de la heurística utilizada, las propiedades estructurales del problema impactan de forma relevante en el rendimiento temporal del *solver*.

La consistencia de estos resultados a través de todas las heurísticas sugiere que

la influencia de estas variables es robusta y generalizable, reafirmando su importancia en el análisis y modelado del comportamiento del solver SAT. Además, el uso del logaritmo del tiempo como variable respuesta ayuda a mitigar la influencia de valores extremos y facilita la detección de diferencias significativas en la mediana y distribución del tiempo.

Pruebas post hoc con test de Dunn

Para estas pruebas se obtuvieron los siguientes resultados:

Test de Dunn para heurística: VSIDS+restart

Variable: num_vars (grupos por cuartiles con ranking) 1 2 3 4 1 1.000000e+00
0.703180 0.000015 1.056421e-07 2 7.031804e-01 1.000000 0.011745 4.209616e-04
3 1.466021e-05 0.011745 1.000000 1.000000e+00 4 1.056421e-07 0.000421 1.000000
1.000000e+00

Variable: densidad (grupos por cuartiles con ranking) 1 2 3 4 1 1.000000
0.000007 0.000503 0.070783 2 0.000007 1.000000 1.000000 0.103465 3 0.000503
1.000000 1.000000 0.872152 4 0.070783 0.103465 0.872152 1.000000

Variable: tamano_prom_clausula (grupos por cuartiles con ranking) 1
2 3 4 1 1.000000e+00 0.123377 0.040784 7.498526e-08 2 1.233771e-01 1.000000
1.000000 6.133981e-03 3 4.078389e-02 1.000000 1.000000 2.285046e-02 4 7.498526e-08
0.006134 0.022850 1.000000e+00

Test de Dunn para heurística: VSIDS+no-restart

Variable: num_vars (grupos por cuartiles con ranking) 1 2 3 4 1 1.000000e+00
0.937707 0.000237 2.446266e-07 2 9.377070e-01 1.000000 0.039659 2.823215e-04
3 2.368724e-04 0.039659 1.000000 1.000000e+00 4 2.446266e-07 0.000282 1.000000
1.000000e+00

Variable: densidad (grupos por cuartiles con ranking) 1 2 3 4 1 1.000000
0.000001 0.000050 0.108825 2 0.000001 1.000000 1.000000 0.027465 3 0.000050
1.000000 1.000000 0.197057 4 0.108825 0.027465 0.197057 1.000000

Variable: tamano_prom_clausula (grupos por cuartiles con ranking) 1
2 3 4 1 1.000000e+00 0.189033 0.004745 3.629837e-08 2 1.890331e-01 1.000000
1.000000 1.485490e-03 3 4.745457e-03 1.000000 1.000000 1.082227e-01 4 3.629837e-08
0.001485 0.108223 1.000000e+00

Test de Dunn para heurística: DLIS+restart

Variable: num_vars (grupos por cuartiles con ranking) 1 2 3 4 1 1.000000e+00
1.000000 0.004494 1.182619e-07 2 1.000000e+00 1.000000 0.058306 1.022282e-05
3 4.494466e-03 0.058306 1.000000 1.668414e-01 4 1.182619e-07 0.000010 0.166841
1.000000e+00

Variable: densidad (grupos por cuartiles con ranking) 1 2 3 4 1 1.000000
0.024023 0.039453 0.005794 2 0.024023 1.000000 1.000000 1.000000 3 0.039453

```

1.000000 1.000000 1.000000 4 0.005794 1.000000 1.000000 1.000000
Variable: tamano_prom_clausula (grupos por cuartiles con ranking) 1
2 3 4 1 1.000000 0.00071 0.078823 0.000005 2 0.000710 1.00000 1.000000 1.000000
3 0.078823 1.00000 1.000000 0.098370 4 0.000005 1.00000 0.098370 1.000000
Test de Dunn para heurística: DLIS+no-restart
Variable: num_vars (grupos por cuartiles con ranking) 1 2 3 4 1 1.000000e+00
0.563525 0.000105 1.981346e-08 2 5.635254e-01 1.000000 0.048111 1.336627e-04
3 1.047943e-04 0.048111 1.000000 7.859709e-01 4 1.981346e-08 0.000134 0.785971
1.000000e+00
Variable: densidad (grupos por cuartiles con ranking) 1 2 3 4 1 1.000000e+00
6.856812e-07 0.001024 0.010847 2 6.856812e-07 1.000000e+00 0.891933 0.174521
3 1.023563e-03 8.919335e-01 1.000000 1.000000 4 1.084705e-02 1.745214e-01
1.000000 1.000000
Variable: tamano_prom_clausula (grupos por cuartiles con ranking) 1
2 3 4 1 1.000000e+00 0.016085 0.029254 5.334288e-09 2 1.608499e-02 1.000000
1.000000 1.063184e-02 3 2.925435e-02 1.000000 1.000000 8.289626e-03 4 5.334288e-09
0.010632 0.008290 1.000000e+00

```

El test post-hoc de Dunn aplicado por cuartiles (grupos definidos con ranking para evitar empates) para cada heurística y variable seleccionada permite identificar con precisión entre qué grupos existen diferencias significativas en el tiempo de resolución (logaritmo del tiempo).

En general, para la variable número de variables, se observan diferencias altamente significativas entre los cuartiles extremos (por ejemplo, grupo 1 vs. 4) en todas las heurísticas, con p-valores muy bajos ($p < 0.001$), lo que confirma que problemas más grandes requieren tiempos significativamente mayores para resolverse. En los grupos intermedios, las diferencias son menos consistentes pero también aparecen comparaciones significativas, evidenciando una relación gradual entre tamaño y tiempo.

Para la densidad, los resultados muestran diferencias significativas principalmente entre los cuartiles más bajos y más altos, aunque en algunos casos los grupos intermedios no difieren tanto, indicando que la densidad afecta el tiempo pero con menor fuerza y de manera menos lineal que el tamaño.

En cuanto al tamaño promedio de cláusula, también se detectan diferencias significativas entre los extremos, especialmente entre el primer y cuarto cuartil, y en varios casos entre grupos adyacentes, lo que sugiere que esta variable influye en el rendimiento, aunque su efecto puede ser más sutil o no monotónico.

La consistencia de estos patrones a lo largo de todas las heurísticas refuerza la importancia de estas características para explicar la variabilidad en el tiempo de resolución.

Conclusiones

La presente tesis ha demostrado que, aunque el algoritmo Conflict-Driven Clause Learning (CDCL) representa un avance significativo en la resolución de problemas SAT al combinar aprendizaje de cláusulas y selección heurística de variables, persiste un dilema fundamental en la dependencia de la heurística inicial para la selección de variables. Este aspecto condiciona el rendimiento del solver, especialmente en problemas con estructuras complejas y gran número de variables, donde la probabilidad de TIMEOUT y los tiempos de resolución se incrementan notablemente, independientemente de la heurística aplicada.

Los resultados estadísticos obtenidos a través de pruebas no paramétricas, regresiones logísticas, análisis de varianza y modelos lineales confirman que el número de variables es el factor más determinante en la eficiencia del solver, seguido por la densidad de cláusulas, cuyo efecto es moderado y en algunos casos inverso, y el tamaño promedio de cláusula, cuya influencia varía según interacciones con otras características. En cuanto al desempeño de las heurísticas, no se identificó una estrategia universalmente óptima; sin embargo, la heurística DLIS sin reinicios mostró un mejor rendimiento promedio y menor tasa de TIMEOUT en problemas medianos y grandes con ciertas estructuras, mientras que las variantes basadas en VSIDS presentaron mayor variabilidad y peor desempeño en instancias densas y grandes, aunque con eficacia en problemas pequeños y medianos.

En conclusión, la investigación subraya la importancia crítica de adaptar la selección heurística y las estrategias de optimización a las características estructurales del problema para maximizar la eficiencia del solver CDCL. Los hallazgos estadísticos robustos orientan hacia el desarrollo de heurísticas adaptativas y modelos predictivos que consideren el tamaño y la estructura del problema, abriendo camino a solucionadores más inteligentes y generalizables. Este trabajo aporta una base sólida para futuras investigaciones que busquen superar el cuello de botella en la selección de variables y perfeccionar la sinergia entre aprendizaje y heurística en algoritmos de satisfacibilidad booleana.

Recomendaciones

Recomendaciones